Business Intelligence

Proyecto final · Entrega 1

Diagnóstico, estrategia y diseño

Observatorio Distrital de Actividad Económica, Turismo y Seguridad de Bogotá D.C.

Integrante	Código
Julian David Avila Cortes	506232041
Santiago Rocha Ramirez	506232712

Dato	Valor
Docente	Leandro Pájaro Fuentes
Fecha de entrega	*23/10/2026*
Repositorio	GitHub - SantiagoRR17/bi-proyecto-equipo506232712 · GitHub

Resumen de la entrega

El caso corresponde a un Observatorio Distrital de Actividad Económica, Turismo y Seguridad de Bogotá D.C. (organización hipotética), cuya dirección no puede comparar de forma integrada la actividad empresarial, los alojamientos turísticos y los hurtos por modalidades, porque las cuatro fuentes públicas (Dinámica empresarial, Establecimientos de alojamiento turístico, Reporte Hurto por Modalidades de la Policía Nacional y Localidad) se administran por separado, en formatos distintos (GeoPackage, GeoJSON, CSV y JSON). La información empresarial y turística tiene referencias territoriales propias (localidad y corte de medición; establecimiento individual), mientras que la fuente policial contiene registros de hurtos con fecha, modalidad y características del hecho; la versión preparada para el proyecto incluye además una columna de localidad que permite integrarla territorialmente con las demás fuentes. Hoy la organización se encuentra en la fase 2 del BIMM (Datos accesibles sin BI) y el proyecto busca llevarla a la fase 5 (Crecimiento del DW y reporting formal) mediante un proceso ETL, un almacén de datos dimensional y un dashboard. El modelo es una constelación de tres tablas de hechos con dimensiones conformadas: FACT_DINAMICA_EMPRESARIAL (una fila por localidad y corte de medición), FACT_ALOJAMIENTO (una fila por establecimiento en la fecha de corte) y FACT_HURTOS (una fila por registro de la fuente policial, con fecha, tipo de hurto, características del hecho y cantidad reportada).

1. Caso de negocio

1.1 Organización y contexto

Para el desarrollo del proyecto se plantea el caso hipotético de un Observatorio Distrital de Actividad Económica, Turismo y Seguridad, organización orientada al análisis de información territorial de Bogotá D.C. y al apoyo de la toma de decisiones relacionadas con la actividad empresarial, el turismo y la seguridad ciudadana. Para efectos del caso, se considera una organización de tamaño mediano, con una sede central y equipos encargados de planeación, análisis y seguimiento de indicadores. El principal decisor es la dirección del observatorio, apoyada por profesionales de las áreas de análisis y planeación.

Actualmente, la organización dispone de diferentes fuentes de información pública, pero estas se encuentran administradas de manera independiente y presentan diferencias en estructura, formato, nivel de detalle y periodicidad. Las fuentes consideradas son: F1, los Establecimientos de alojamiento turístico de Bogotá, que representa geográficamente los establecimientos de hospedaje; F2, el Reporte Hurto por Modalidades de la Policía Nacional, un archivo CSV de registros de hurtos que incluye fecha del hecho, tipo de hurto, arma o medio reportado, género, grupo etario y cantidad, entre otros campos; F3, la Dinámica empresarial de Bogotá D.C., que contiene empresas y establecimientos vigentes por localidad y corte de medición; y F4, la Localidad de Bogotá D.C., utilizada como referencia geográfica para integrar las demás fuentes.

El problema de negocio surge porque la información no se encuentra integrada en un modelo común que permita realizar análisis consistentes. Las fuentes presentan tres tipos de grano: la dinámica empresarial se distribuye en archivos de diferentes años y maneja indicadores por localidad y corte de medición (septiembre de 2023, marzo de 2024 y julio de 2025), por lo que no constituye una serie continua; los establecimientos de alojamiento se representan como entidades individuales con información geográfica; y los hurtos se registran como eventos de la fuente policial con fecha, modalidad y características del hecho. Adicionalmente, las fuentes difieren en la representación de los códigos y nombres de localidad (por ejemplo, "3" frente a "03"), en los formatos de fecha y en los sistemas de referencia espacial, aspectos que deben tratarse durante la integración. La columna de localidad de los hurtos permite integrarlos con las demás fuentes por territorio.

Como consecuencia, actualmente el decisor no cuenta con una visión integrada que le permita comparar la actividad empresarial por localidad, la concentración de establecimientos de alojamiento turístico y la evolución de los hurtos por fecha y modalidad en los periodos disponibles. Esta situación dificulta identificar concentraciones, comparar periodos y realizar seguimiento histórico utilizando criterios homogéneos.

La solución propuesta consiste en implementar una arquitectura de Business Intelligence que permita extraer las fuentes, realizar procesos de integración y transformación, normalizar los identificadores territoriales y temporales y almacenar la información en un modelo dimensional. Posteriormente, la información podrá ser consultada mediante herramientas de análisis y visualización para generar indicadores y reportes que faciliten la toma de decisiones.

El propósito del proyecto no es establecer relaciones causales entre la actividad económica, el turismo y la seguridad, sino proporcionar una visión descriptiva e integrada de la información disponible. La comparación entre fuentes es descriptiva y no pretende explicar causas de la seguridad ciudadana.

1.2 Síntomas de arquitectura accidental

#	Síntoma	Evidencia en el caso	Capa afectada
S1	**Información distribuida en fuentes independientes**	Los datos de dinámica empresarial (GPKG), alojamiento turístico (GeoJSON), hurtos (CSV) y localidades (JSON) provienen de conjuntos distintos, con formatos y estructuras diferentes. Esto obliga a homologarlos antes de analizarlos conjuntamente.	Fuentes
S2	**Diferencias en la granularidad de los datos**	La dinámica empresarial presenta indicadores por localidad y corte de medición; los alojamientos se representan como registros individuales con ubicación; y los hurtos son registros policiales con fecha, modalidad y características del hecho (176.776 filas de Bogotá). Una unión directa duplicaría registros o distorsionaría las métricas.	Integración
S3	**Códigos, nombres, fechas y categorías requieren normalización**	En alojamiento turístico aparece LOCALIDAD = "3", mientras que la fuente de localidades usa LocCodigo de dos caracteres ("03"); en dinámica empresarial 2025 LOCCODIGO no coincide con el código oficial; y FECHA HECHO de los hurtos llega como texto con formato dd/mm/aaaa.	Integración
S4	**Calidad semántica: localidad en la fuente de hurtos**	Los campos originales de la fuente policial (DEPARTAMENTO, MUNICIPIO y CODIGO DANE) solo identifican a Bogotá D.C. como un todo; la localidad se incorpora en la columna LOCALIDAD del CSV, con nombres con tildes que difieren de F4 y requieren una tabla de equivalencia.	Integración y almacén de datos

1.3 Preguntas de negocio

#	Pregunta	Tipo (BI, BA o Big Data)	Por qué es de ese tipo
P0	¿Cómo se distribuyen y evolucionan la actividad empresarial, los establecimientos de alojamiento turístico y los hurtos por modalidades en Bogotá D.C., de acuerdo con los periodos disponibles y las limitaciones territoriales de cada fuente?	BI	Describe y compara información histórica estructurada de tres procesos para apoyar la decisión; no predice ni recomienda.
P1	¿Qué localidades registran los mayores valores de empresas y establecimientos vigentes, y cómo evolucionan estos indicadores entre los cortes disponibles de septiembre de 2023, marzo de 2024 y julio de 2025?	BI	Utiliza datos históricos estructurados en tres cortes puntuales, que no forman una serie mensual continua, para comparar localidades. Los establecimientos vigentes de 2023 no están disponibles en la fuente. No predice el comportamiento futuro.
P2	¿Cómo se distribuyen los establecimientos de alojamiento turístico entre las localidades de	BI	Es un análisis descriptivo de la distribución territorial. Las subcategorías se reportan por su código

#	Pregunta	Tipo (BI, BA o Big Data)	Por qué es de ese tipo
	Bogotá y qué subcategorías están representadas en la fuente?		original (SUBCATRNT), porque el diccionario no permite verificar sus nombres.
P3	¿Cómo evolucionan los registros y las cantidades reportadas de hurtos por fecha, tipo de hurto y otras características disponibles en la fuente policial?	BI	Describe la evolución temporal a nivel Bogotá y por modalidad con los campos originales, sin predecir. Puede desagregarse por localidad.
P4	¿Cómo pueden compararse descriptivamente los indicadores empresariales, la oferta de alojamiento y las tendencias de hurto durante los periodos disponibles, sin inferir causalidad?	BI	Es un análisis comparativo y descriptivo de información histórica integrada, no predictivo; no busca causalidad.

2. Inventario de fuentes

F1 – Establecimientos de alojamiento turístico (Instituto Distrital de Turismo): ubicación y subcategoría de 839 prestadores de alojamiento inscritos en el Registro Nacional de Turismo, representados como puntos geográficos (GeoJSON).

F2 – Reporte Hurto por Modalidades - Policía Nacional (Datos.gov.co, https://www.datos.gov.co/Seguridad-y-Defensa/Reporte-Hurto-por-Modalidades-Polic-a-Nacional/6sqw-8cg5): registros de hurtos en formato CSV con las columnas originales DEPARTAMENTO, MUNICIPIO, CODIGO DANE, ARMAS MEDIOS, FECHA HECHO, GENERO, GRUPO ETARIO, TIPO DE HURTO y CANTIDAD. El archivo tiene 653.384 filas de todo el país; el proyecto usa las 176.776 filas de Bogotá D.C. (DEPARTAMENTO = BOGOTA, que coincide con MUNICIPIO = Bogotá D.C. (CT) y CODIGO DANE = 11001000), con fechas del 01/01/2010 al 31/07/2026. El CSV del proyecto incluye además la columna LOCALIDAD, que no pertenece a la fuente original: el equipo la asignó a los registros de Bogotá, con autorización del docente, para poder integrar este reporte con F4 y probar el modelo territorial.

F3 – Dinámica empresarial (Secretaría Distrital de Desarrollo Económico, con registros de la Cámara de Comercio de Bogotá): empresas y establecimientos vigentes, creados y cancelados por localidad, tamaño, rama de actividad y organización jurídica, en tres cortes (2023, 2024 y 2025).

F4 – Localidad (Secretaría Distrital de Planeación): las 20 localidades de Bogotá con código, nombre, área y contorno; sirve de referencia geográfica para integrar las demás fuentes.

2.1 Fuentes

Fuente	Procedencia (URL)	Formato	Registros	Periodo	Fecha de descarga	Licencia
F1	Establecimiento de Alojamiento Turístico. Bogotá - Conjunto de datos - Datos Abiertos Bogotá	Geojson	839 establecimientos	Sin campo de fecha; corte de la descarga (22/10/2026)	22/10/2026	Creative Commons Attribution Share-Alike 4.0
F2	Reporte Hurto por Modalidades -	CSV	176.776 filas de Bogotá (de 653.384 del	01/01/2010 a 31/07/2026	22/10/2026	Creative Commons 4.0

Fuente	Procedencia (URL)	Formato	Registros	Periodo	Fecha de descarga	Licencia
	Policía Nacional - Datos.gov.co		archivo); suma de CANTIDAD = 176.776	(2026 parcial: enero a julio)		
F3	Dinámica empresarial. Bogotá D.C. - Conjunto de datos - Datos Abiertos Bogotá	gpkg	119.893 empresas + 12.923 establecimientos + 57 filas resumen por localidad (3 archivos)	Septiembre 2023, marzo 2024 y julio 2025 (un corte por archivo)	22/10/2026	Creative Commons Attribution Share-Alike 4.0
F4	Localidad. Bogotá D.C - Conjunto de datos - Datos Abiertos Bogotá	json	20 localidades	No aplica (referencia geográfica; Acuerdo 117 de 2003)	22/10/2026	Creative Commons Attribution Share-Alike 4.0

2.2 Problemas de calidad detectados

Fuente	Campo	Problema	Ejemplo real del dato
F1	LOCALIDAD	Código de localidad guardado como texto sin cero a la izquierda; no coincide con LocCodigo de la fuente de localidades.	"3" en F1 frente a "03" en F4 (438 de los 839 registros tienen un solo dígito).
F1	geometría / LATITUD, LONGITUD	El mismo registro trae dos sistemas de coordenadas: la geometría está en EPSG:3857 (metros) y LATITUD/LONGITUD en grados.	HOTEL DANN: geometría [-8245514.99, 513176.96] frente a LATITUD 4.60498 y LONGITUD -74.07072.
F1	SUBCATRNT	El dato usa códigos numéricos, pero el dominio del diccionario (Subcategoría RNT) usa letras de la A a la Z; no se puede asignar con certeza la etiqueta del tipo de alojamiento.	SUBCATRNT = "9" (668 de 839 registros); el diccionario define "K- HOTEL", "I- APARTAHOTEL", "J- HOSTAL".
F2	DEPARTAMENTO, MUNICIPIO, CODIGO DANE	Los tres campos solo identifican a Bogotá D.C. como un todo y coinciden en las mismas 176.776 filas; no permiten determinar la localidad. DEPARTAMENTO escribe BOGOTA sin tilde y MUNICIPIO escribe Bogotá D.C. (CT) con tilde.	BOGOTA / Bogotá D.C. (CT) / 11001000 (176.776 de 653.384 filas).
F2	FECHA HECHO	Texto con formato dd/mm/aaaa (393.446 filas tienen día mayor que 12, lo que confirma el orden día/mes); se convierte a fecha. No hay valores inválidos ni faltantes. El rango real es 2010 a 2026 y 2026 es parcial (enero a julio). El volumen anual de Bogotá pasa de 4.372 (2016) a 16.730 (2017) registros; no se	15/07/2026; mínimo 01/01/2010; máximo 31/07/2026.

Fuente	Campo	Problema	Ejemplo real del dato
		interpreta como un cambio real sin validar la cobertura de la fuente.	
F2	CANTIDAD	Texto numérico sin nulos, negativos ni ceros; vale 1 en todas las filas, por lo que la suma de CANTIDAD (176.776 en Bogotá; 653.384 en todo el archivo) es igual al número de filas. Aun así se distingue entre filas y suma de CANTIDAD, porque la fuente no documenta que cada fila sea un hecho individual.	CANTIDAD = 1 en 176.776 de 176.776 filas de Bogotá.
F2	GENERO, GRUPO ETARIO	GENERO está vacío en 160.540 de 176.776 filas de Bogotá (90,8%); la modalidad de residencias tiene el género informado en sus 16.175 filas, que son 16.175 de los 16.236 valores informados en total. GRUPO ETARIO está vacío en 14.811 filas (8,4%). Los vacíos no se completan con categorías supuestas.	GENERO: MASCULINO 8.650, FEMENINO 7.584, NO REPORTA 2, vacío 160.540.
F2	TIPO DE HURTO, ARMAS MEDIOS	Solo hay dos tipos de hurto (ARTÍCULO 239. HURTO ENTIDADES COMERCIALES y ARTÍCULO 239. HURTO RESIDENCIAS) y el de residencias aparece solo desde 2024, por lo que no se pueden comparar modalidades antes de 2024. ARMAS MEDIOS incluye la categoría NO REPORTADO.	Residencias: 0 filas hasta 2023 y 6.095 en 2024; ARMAS MEDIOS = NO REPORTADO en 1.114 filas.
F2	LOCALIDAD	Columna de localidad añadida al CSV del proyecto, presente en las 176.776 filas de Bogotá (cerca de 8.800 por localidad, incluida Sumapaz); las demás filas quedan sin localidad. Los nombres llevan tildes y "La Candelaria" frente a "CANDELARIA" en F4, por lo que se relacionan con LocCodigo mediante una tabla de equivalencia explícita.	Suba, La Candelaria (476.608 filas fuera de Bogotá sin localidad).
F2	Duplicados	No existe un identificador de registro. 144.063 de las 176.776 filas de Bogotá repiten los nueve campos originales de otra fila, lo cual es esperable en una fuente de eventos con CANTIDAD = 1. No se eliminan filas: el ETL solo marca los duplicados potenciales y conserva todas.	01/01/2010, ARMA BLANCA / CORTOPUNZANTE, ADULTOS, HURTO ENTIDADES COMERCIALES, CANTIDAD 1 (2 filas).
F3	LOCCODIGO / LOCNOMBRE (capa Empresas)	Código y nombre inconsistentes entre archivos: en 2023 y 2024 LOCNOMBRE contiene el código; en 2025 LOCCODIGO es un índice alfabético que no coincide con el código oficial. Existe además el	2025: LOCCODIGO 2 = "Candelaria" (oficial 17) y 19 = "Chapinero" (oficial 02); 2023: LOCNOMBRE = "01".

Fuente	Campo	Problema	Ejemplo real del dato
		código 21 ("Sin Localidad"), que no es una localidad.	
F3	EstablecimientosVigentes (2023)	Valor nulo: en 2023 el resumen no trae establecimientos y la capa Establecimientos está vacía, lo que impide comparar 2023 con 2024 y 2025.	19 de 19 filas nulas en dinamicaempresarial2023.gpkg; capa Establecimientos con 0 registros.
F3	LOCNOMBRE / Periodo	Grafía distinta del nombre de la localidad según el archivo y un solo corte por año, con meses diferentes.	"USAQUEN" (2023), "Usaquén" (resumen 2025), "Usaquen" (empresas 2025); cortes 2023-09, 2024-03 y 2025-07.
F4	LocNombre	Nombres en mayúscula y sin tildes, que no coinciden con el catálogo del diccionario de Dinámica empresarial.	"USAQUEN" y "SANTA FE" frente a "Usaquén" y "Santa Fé".
F4	Sistema de referencia y diccionario	Usa MAGNA-SIRGAS (EPSG:4686), distinto de F1 (3857) y F3 (4326), y la fuente no publica diccionario de datos.	spatialReference wkid 4686; no existe diccionario en /datos/diccionarios (se elabora en el Anexo A.4).

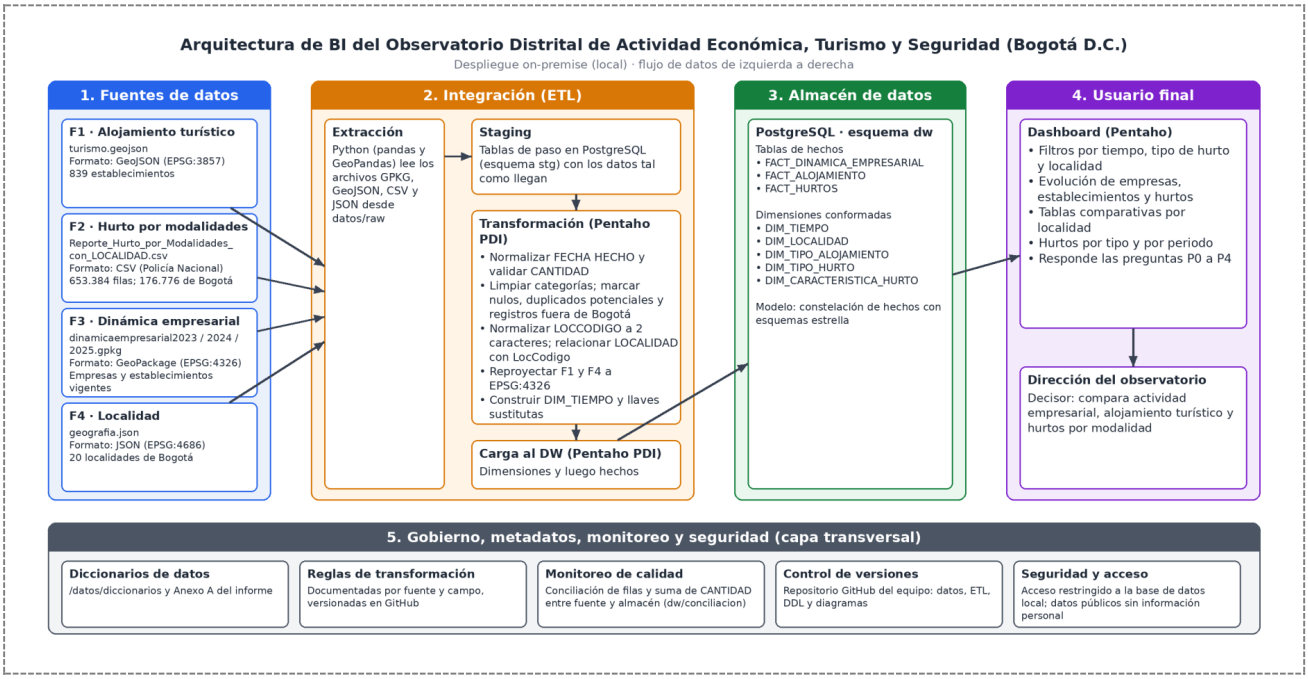
3. Diagnóstico de madurez

Elemento	Respuesta
Fase actual	Fase 2 – Datos accesibles sin BI
Evidencia	S1: las cuatro fuentes (GPKG, GeoJSON, CSV y JSON) están separadas y tienen estructuras diferentes. S2: las fuentes presentan granos distintos (localidad y corte, establecimiento y registro policial). S3: los códigos de localidad, las fechas y las categorías requieren normalización. S4: la calidad de la fuente policial debe validarse (fechas, CANTIDAD, campos vacíos, duplicados potenciales y localidad).
Por qué no es la fase siguiente	No existe evidencia de un proceso formal de decisión basado en una solución BI integrada. Los datos están disponibles, pero no existe un modelo dimensional, procesos ETL consolidados, almacén de datos ni una capa formal de análisis que permita consultar conjuntamente los indicadores.
Fase objetivo al final del proyecto	5. Crecimiento del DW y reporting formal
Brechas que cierra el proyecto	Fuentes: centralizar F1 a F4 (GeoJSON, CSV, GPKG y JSON) en un flujo de adquisición definido (capa 1 de la tabla 4.2). Integración: ETL con Pentaho PDI y Python para limpiar y normalizar los registros policiales (fechas, categorías y cantidades), los códigos territoriales y los sistemas de referencia (capa 2 de la tabla 4.2). Almacén de datos: modelo dimensional en PostgreSQL para almacenar la información integrada (capa 3 de la tabla 4.2). Usuario final: dashboard en Pentaho con indicadores empresariales, de alojamiento y de hurtos por modalidad (capa 4 de la tabla 4.2). Gobierno, metadatos, monitoreo y seguridad: diccionarios, reglas de

Elemento	Respuesta
	transformación, conciliación de filas y cantidades, documentación de la localidad y acceso restringido (capa 5 de la tabla 4.2).

4. Arquitectura

4.1 Diagrama de cinco capas del caso



4.2 Componentes por capa

Capa	Componentes y herramientas del caso	Función en el caso
1. Fuentes de datos	F1 turismo.geojson; F2 Reporte_Hurto_por_Modalidades_con_LOCALIDAD.csv (CSV de la Policía Nacional con la columna LOCALIDAD); F3 dinamicaempresarial2023.gpkg, dinamicaempresarial2024.gpkg y dinamicaempresarial2025.gpkg; F4 geografia.json. F1, F3 y F4 están en la carpeta datos/raw del repositorio.	Proveer los datos públicos en su formato original, sin modificarlos; F2 incluye la columna LOCALIDAD para la integración territorial.
2. Integración (ETL)	Python (pandas y GeoPandas) para leer el CSV, GPKG, GeoJSON y JSON; Pentaho Data Integration para las transformaciones y trabajos (carpetas etl/transformaciones y etl/trabajos); área de staging.	Leer el CSV, normalizar FECHA HECHO a fecha, validar CANTIDAD, limpiar categorías, normalizar LOCCODIGO a dos caracteres, reproyectar F1 y F4 a EPSG:4326, relacionar LOCALIDAD con el código oficial, identificar nulos, registros fuera de Bogotá y duplicados potenciales (sin eliminarlos) y cargar dimensiones y hechos.

Capa	Componentes y herramientas del caso	Función en el caso
3. Almacén de datos	PostgreSQL en el equipo local con esquema dimensional (3 tablas de hechos y 5 dimensiones); scripts en dw/ddl y verificaciones en dw/conciliacion.	Almacenar la información integrada y preparada para análisis, con DIM_LOCALIDAD y DIM_TIEMPO compartidas entre los hechos cuando las llaves son compatibles.
4. Usuario final	Dashboard en Pentaho (carpeta dashboard) con filtros por tiempo, tipo de hurto y localidad, tablas comparativas y mapa por localidad.	Permitir a la dirección responder las preguntas P0 a P4 sin manipular los archivos originales.
5. Gobierno, metadatos, monitoreo y seguridad	Diccionarios de datos (/datos/diccionarios y Anexo A), reglas de transformación documentadas, documentación de las limitaciones analíticas, conciliación de filas y cantidades entre fuente y almacén, repositorio GitHub y acceso restringido a la base local.	Documentar el origen y las reglas de cada dato, controlar la calidad de la carga, advertir las limitaciones analíticas y limitar el acceso a la información.

4.3 Marco de Referencia de cuatro categorías

Categoría	Decisión tomada	Justificación
Arquitectura de información	Se analizan tres procesos (actividad empresarial, alojamiento turístico y hurtos por modalidades) con datos públicos sin información personal.	Responde las preguntas P0 a P4 con las fuentes del inventario. El alcance es descriptivo: no se infiere causalidad ni se presentan resultados territoriales de hurtos como hechos reales.
Arquitectura de datos	Modelo dimensional de constelación: FACT_DINAMICA_EMPRESARIAL, FACT_ALOJAMIENTO y FACT_HURTOS, con DIM_TIEMPO, DIM_LOCALIDAD, DIM_TIPO_ALOJAMIENTO, DIM_TIPO_HURTO y DIM_CARACTERISTICA_HURTO; código de localidad de dos caracteres como llave de DIM_LOCALIDAD.	Los granos son distintos (localidad y corte, establecimiento, registro policial). Hechos separados evitan duplicar registros y las dimensiones conformadas de tiempo y localidad permiten compararlos.
Arquitectura técnica	ETL con Python y Pentaho Data Integration, base de datos PostgreSQL y repositorio GitHub, todo ejecutado de forma local.	Son herramientas gratuitas y suficientes para unas 787 mil filas de entrada (653.384 del CSV de hurtos, unas 133 mil de dinámica empresarial y unas 900 de alojamiento y localidades); Python lee los formatos y Pentaho orquesta la carga.
Arquitectura de producto	Dashboard con indicadores empresariales, de alojamiento y de hurtos por modalidad, con filtros y comparaciones.	Es el producto que consulta la dirección; cada visualización se traza a una pregunta de la tabla 1.3 (ver 5.6).

4.4 Decisión de despliegue

Criterio	On-premise	Opción cloud:Azure PaaS	Elegida y por qué
Costo	Requiere adquirir y mantener servidores, almacenamiento, infraestructura de red, respaldos y	Permite utilizar recursos bajo demanda y reducir la inversión inicial en infraestructura física.	On-premise (local). Es un proyecto académico: se usan herramientas gratuitas en equipos propios y no se justifica pagar servicios de Azure.

Criterio	On-premise	Opción cloud:Azure PaaS	Elegida y por qué
	actualizaciones. Tiene mayor inversión inicial.	El costo depende de los servicios y recursos utilizados.	
Seguridad y cumplimiento	La organización controla directamente servidores, redes, almacenamiento y políticas de acceso, pero debe asumir la responsabilidad de su configuración y mantenimiento.	Azure proporciona mecanismos de autenticación, control de acceso, cifrado, monitoreo y cumplimiento, mientras la organización mantiene responsabilidad sobre la configuración y los datos.	On-premise (local). Los datos son públicos y no contienen información personal; el acceso se controla en el equipo y en la base de datos local.
Escalabilidad	Para aumentar capacidad es necesario adquirir, instalar y configurar nuevos recursos físicos.	Los recursos pueden aumentar o disminuir según las necesidades de procesamiento, almacenamiento y usuarios.	On-premise (local). El volumen es de unas 787 mil filas de entrada y la tabla de hechos mayor tiene 176.776 filas; un equipo local es suficiente.
Acceso móvil	Requiere configurar infraestructura de acceso remoto, VPN y mecanismos de seguridad propios.	Los servicios pueden ser consumidos mediante aplicaciones web y herramientas BI desde dispositivos autorizados con conexión a Internet.	On-premise (local). No se requiere acceso móvil: el dashboard se consulta y se presenta desde el equipo del proyecto.

Opción elegida: despliegue on-premise (local). En un caso real sería preferible una opción en la nube por su escalabilidad y menor mantenimiento, pero al tratarse de un ejercicio académico que no se desplegará en un proveedor, el almacén de datos y el dashboard se ejecutan localmente.

5. Modelo dimensional

Se selecciona un modelo dimensional basado en esquemas estrella, organizado como una constelación de hechos, debido a que las fuentes presentan granos distintos: localidad y corte de medición (dinámica empresarial), establecimiento individual (alojamiento turístico) y registro policial con fecha, modalidad y características del hecho (hurtos). Unificar toda la información en una única tabla de hechos produciría duplicidad de registros y resultados incorrectos. Por esta razón se plantean tres tablas de hechos independientes (FACT_DINAMICA_EMPRESARIAL, FACT_ALOJAMIENTO y FACT_HURTOS) que comparten dimensiones conformadas, principalmente DIM_TIEMPO y DIM_LOCALIDAD, solo cuando las llaves son compatibles. La relación de FACT_HURTOS con DIM_LOCALIDAD se hace con una tabla de equivalencia de nombres y códigos. Las características del hecho (arma o medio, género y grupo etario) se modelan en una dimensión de características, DIM_CARACTERISTICA_HURTO, porque combinan

pocos valores (como máximo 10 × 4 × 4 combinaciones) y así no se repite texto en las 176.776 filas de la tabla de hechos.

5.1 Proceso de negocio

El proceso de negocio que se modela corresponde al monitoreo territorial de Bogotá D.C., mediante el cual la organización adquiere, limpia, integra, almacena en un modelo dimensional y visualiza datos empresariales, turísticos y policiales. El proceso inicia con la adquisición periódica de las fuentes de datos públicas, continúa con la validación y transformación de la información y posteriormente integra los registros mediante dimensiones comunes, principalmente tiempo y localidad. Finalmente, la información consolidada se usa para generar indicadores, comparaciones y reportes que apoyan las decisiones de la dirección del observatorio.

Debido a que las fuentes poseen diferentes granos, el modelo utiliza tres tablas de hechos relacionadas con procesos específicos: dinámica empresarial, alojamiento turístico y hurtos por modalidades. La integración por localidad se hace mediante DIM_LOCALIDAD y la tabla de equivalencia de nombres.

5.2 Granularidad

El modelo define tres tablas de hechos, cada una con su propio grano:

FACT_DINAMICA_EMPRESARIAL

Una fila de la tabla de hechos representa una localidad en un corte de medición de la dinámica empresarial, con las medidas disponibles en ese corte.

FACT_ALOJAMIENTO

Una fila de la tabla de hechos representa un establecimiento de alojamiento turístico, identificado por su código del Registro Nacional de Turismo y ubicado en una localidad, en la fecha de corte de la fuente.

FACT_HURTOS

Una fila de la tabla de hechos representa un registro de la fuente policial de hurtos ocurrido en Bogotá D.C., con su fecha del hecho, tipo de hurto, arma o medio, género, grupo etario, cantidad reportada (CANTIDAD) y localidad. No se asume que cada fila sea un hecho individual y no se agrupan ni se eliminan filas.

5.3 Métricas de la tabla de hechos

FACT_DINAMICA_EMPRESARIAL			
Métrica	**Tipo de dato**	**Aditividad**	**Origen o fórmula**
Empresas vigentes	Entero	**Semiaditiva respecto al tiempo; aditiva respecto a localidad cuando se suman unidades territoriales sin duplicar periodos**	Campo EmpresasVigentes de Dinámica Empresarial

Establecimientos vigentes	Entero	**Semiaditiva respecto al tiempo; aditiva respecto a localidad**	Campo EstablecimientosVigentes (no disponible en el corte de 2023)
Variación de empresas vigentes	Decimal	No aditiva	(Empresas periodo actual - Empresas periodo anterior) / Empresas periodo anterior × 100
Variación de establecimientos vigentes	Decimal	No aditiva	(Establecimientos periodo actual - Establecimientos periodo anterior) / Establecimientos periodo anterior × 100
FACT_ALOJAMIENTO			
Métrica	**Tipo de dato**	**Aditividad**	**Origen o fórmula**
Cantidad de alojamientos	Entero	Aditiva	COUNT(*) de establecimientos (una fila = un establecimiento)
Participación de alojamientos por localidad (%)	Decimal	No aditiva	Alojamientos localidad / Alojamientos Bogotá × 100
FACT_HURTOS			
Métrica	**Tipo de dato**	**Aditividad**	**Origen o fórmula**
Número de registros de la fuente	Entero	Aditiva	COUNT(*) de filas de FACT_HURTOS; no equivale necesariamente a la cantidad de hurtos
Cantidad reportada	Entero	Aditiva respecto a todas las dimensiones	SUM(CANTIDAD) después de validar sus valores (en el archivo todas las filas valen 1)
Participación por tipo de hurto (%)	Decimal	No aditiva	Cantidad del tipo de hurto / cantidad total comparable × 100
Variación temporal (%)	Decimal	No aditiva	(Cantidad periodo actual − cantidad periodo equivalente anterior) / cantidad periodo anterior × 100; solo entre periodos equivalentes y completos (por ejemplo, enero a julio)

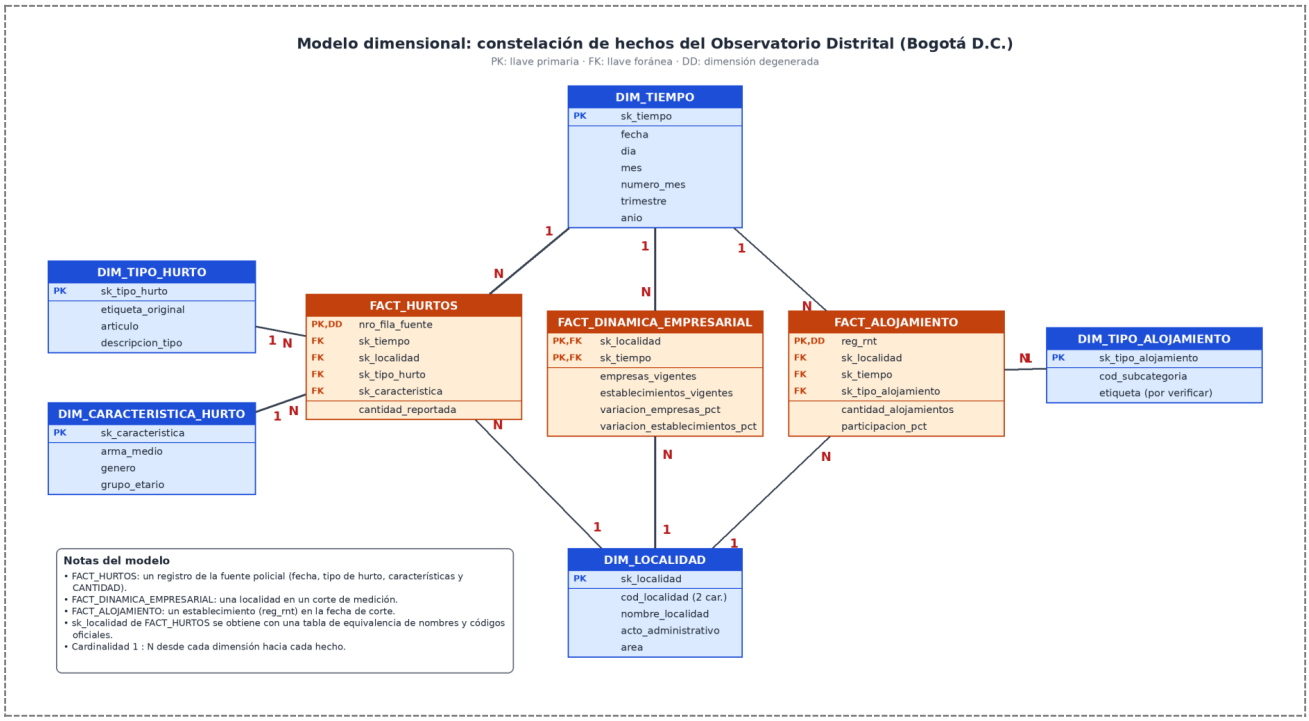
5.4 Dimensiones

Dimensión	Atributos principales	Jerarquía	Fuente
DIM_TIEMPO	Fecha, día, mes, número de mes, trimestre, año	Día → Mes → Trimestre → Año	Generada
DIM_LOCALIDAD	Código localidad (2 caracteres), nombre localidad, acto administrativo, área	Bogotá → Localidad	Localidad Bogotá D.C. (F4)

Dimensión	Atributos principales	Jerarquía	Fuente
DIM_TIPO_ALOJAMIENTO	Código de subcategoría (SUBCATRNT); la etiqueta se asigna solo si se verifica con el diccionario	No aplica (solo código verificable)	Alojamiento turístico (F1)
DIM_TIPO_HURTO	Etiqueta original (TIPO DE HURTO), artículo, descripción del tipo	Artículo → Tipo de hurto	Reporte Hurto por Modalidades (F2)
DIM_CARACTERISTICA_HURTO	Arma o medio, género, grupo etario (los vacíos de la fuente se representan como «SIN DATO», sin suponer categorías)	No aplica	Reporte Hurto por Modalidades (F2)

Notas de diseño: las características del hurto se modelan en una dimensión propia y no en la tabla de hechos porque combinan pocos valores y se repetirían en 176.776 filas. FACT_HURTOS conserva nro_fila_fuente como identificador de trazabilidad hacia el CSV. La relación de FACT_HURTOS con DIM_LOCALIDAD se establece mediante una tabla de equivalencia explícita de los 20 nombres del CSV con los 20 códigos oficiales (relación uno a uno verificada), no por coincidencia aproximada de nombres.

5.5 Diagrama del esquema



Nota: reg_rnt (código del Registro Nacional de Turismo) es una dimensión degenerada de FACT_ALOJAMIENTO; nro_fila_fuente es una dimensión degenerada de FACT_HURTOS. Los archivos editables (draw.io) y los PNG se entregan en /docs/diagramas.

Se elige esquema estrella, y no copo de nieve, porque las dimensiones son pequeñas y sus jerarquías (Día → Mes → Trimestre → Año; Bogotá → Localidad; Artículo → Tipo de hurto) pueden guardarse como atributos de una sola tabla por dimensión. Esto reduce las uniones, simplifica las consultas del

dashboard y mantiene un solo camino de cada hecho a DIM_LOCALIDAD y DIM_TIEMPO, que son las dimensiones conformadas que permiten comparar las tres tablas de hechos.

5.6 Trazabilidad con las preguntas

Pregunta	Métricas que usa	Dimensiones que usa
P0	Empresas vigentes, establecimientos vigentes, cantidad de alojamientos, cantidad reportada de hurtos y número de registros	DIM_TIEMPO, DIM_TIPO_HURTO, DIM_LOCALIDAD, DIM_TIPO_ALOJAMIENTO
P1	Empresas vigentes, establecimientos vigentes, variación de empresas %, variación de establecimientos % (entre los cortes disponibles; los establecimientos de 2023 no están disponibles)	DIM_LOCALIDAD, DIM_TIEMPO
P2	Cantidad de alojamientos, participación de alojamientos %	DIM_LOCALIDAD, DIM_TIPO_ALOJAMIENTO (código SUBCATRNT), DIM_TIEMPO
P3	Cantidad reportada, número de registros, participación por tipo de hurto %, variación temporal %	DIM_TIEMPO, DIM_TIPO_HURTO, DIM_CARACTERISTICA_HURTO
P4	Empresas vigentes, establecimientos vigentes, cantidad de alojamientos y cantidad reportada de hurtos (en periodos equivalentes y completos), con sus participaciones y variaciones	DIM_TIEMPO, DIM_LOCALIDAD, DIM_TIPO_ALOJAMIENTO, DIM_TIPO_HURTO

Nota metodológica sobre comparabilidad temporal y territorial. La dinámica empresarial tiene tres cortes puntuales (septiembre de 2023, marzo de 2024 y julio de 2025) y no forma una serie anual o mensual continua; los establecimientos vigentes de 2023 no están disponibles. Los hurtos tienen fechas entre el 01/01/2010 y el 31/07/2026, con 2026 parcial (enero a julio); las comparaciones entre años se hacen con periodos equivalentes y completos (por ejemplo, enero a julio de cada año). El corte de alojamiento corresponde a la fecha de descarga de la fuente (22/10/2026). Los valores empresariales son indicadores de existencia en un corte, mientras que los hurtos son registros o cantidades reportadas durante periodos, por lo que no se comparan como magnitudes equivalentes: la comparación es descriptiva y de tendencias. Además, el tipo de hurto "residencias" aparece en la fuente solo desde 2024, por lo que las variaciones por modalidad anteriores a 2024 no son comparables.

6. Referencias

Instituto Distrital de Turismo. (2025). *Establecimiento de alojamiento turístico. Bogotá* [Conjunto de datos]. Datos Abiertos Bogotá. https://datosabiertos.bogota.gov.co/dataset/establecimiento-de-alojamiento-turistico-bogota

Policía Nacional de Colombia. (s. f.). *Reporte Hurto por Modalidades - Policía Nacional* [Conjunto de datos]. Datos.gov.co. https://www.datos.gov.co/Seguridad-y-Defensa/Reporte-Hurto-por-Modalidades-Polic-a-Nacional/6sqw-8cg5

Secretaría Distrital de Desarrollo Económico. (2026). *Dinámica empresarial. Bogotá D.C.* [Conjunto de datos]. Datos Abiertos Bogotá. https://datosabiertos.bogota.gov.co/dataset/dinamica-empresarial-bogota

Secretaría Distrital de Planeación. (2022). *Localidad. Bogotá D.C.* [Conjunto de datos]. Datos Abiertos Bogotá. https://datosabiertos.bogota.gov.co/dataset/localidad-bogota-d-c

Anexos

Anexo A. Diccionarios de datos

A.1 F1 – Establecimientos de alojamiento turístico (turismo.geojson)

Campo	Tipo	Descripción	Ejemplo	Problema de calidad
REGNTURISM	Entero	Código único del prestador de servicios turísticos en el Registro Nacional de Turismo (RNT).	396	Sin duplicados ni nulos en los 839 registros.
NOMESTABLE	Texto	Nombre comercial del establecimiento, según el RNT.	HOTEL DANN	Sin nulos.
SUBCATRNT	Texto	Subcategoría a la que pertenece el establecimiento según el RNT.	9	Códigos numéricos (6 a 12); el dominio del diccionario usa letras (A a Z). "9" aparece en 668 registros. No se asignan etiquetas sin verificación.
LOCALIDAD	Texto	Localidad donde se ubica el establecimiento.	3	Sin cero a la izquierda ("3" frente a "03"); no hay registros de las localidades 4, 19 ni 20.
SECCATASTR	Texto	Sector catastral donde se ubica el establecimiento.	LAS NIEVES	El diccionario lo nombra SECCATRASTR.
LATITUD	Decimal	Latitud del punto anonimizado, en grados.	4.604981234	Sistema distinto al de la geometría (EPSG:3857).
LONGITUD	Decimal	Longitud del punto anonimizado, en grados.	-74.07072137	Sistema distinto al de la geometría (EPSG:3857).
geometry	Punto	Ubicación geográfica del establecimiento (EPSG:3857).	[-8245514.99, 513176.96]	CRS distinto a F3 (4326) y F4 (4686).

A.2 F2 – Reporte Hurto por Modalidades - Policía Nacional (Reporte_Hurto_por_Modalidades_con_LOCALIDAD.csv)

Campo	Tipo	Descripción	Ejemplo	Problema de calidad
DEPARTAMENTO	Texto	Departamento del hecho; la fuente identifica a Bogotá como BOGOTA.	BOGOTA	Se filtra DEPARTAMENTO = BOGOTA (176.776 de 653.384 filas); sin nulos.
MUNICIPIO	Texto	Municipio del hecho.	Bogotá D.C. (CT)	Coincide con DEPARTAMENTO = BOGOTA en las 176.776 filas; no indica localidad.

Campo	Tipo	Descripción	Ejemplo	Problema de calidad
CODIGO DANE	Entero	Código DANE del municipio.	11001000	Código de Bogotá D.C.; no permite determinar la localidad.
ARMAS MEDIOS	Texto	Arma o medio empleado en el hecho.	SIN EMPLEO DE ARMAS	10 categorías en Bogotá; incluye NO REPORTADO (1.114 filas). Se limpia sin completar valores.
FECHA HECHO	Fecha (texto dd/mm/aaaa)	Fecha en que ocurrió el hecho.	15/07/2026	Se normaliza a fecha ISO; rango 01/01/2010 a 31/07/2026; 2026 parcial (enero a julio); sin valores inválidos.
GENERO	Texto	Género registrado en el hecho.	MASCULINO	Vacío en 160.540 de 176.776 filas de Bogotá (90,8%); valores: MASCULINO, FEMENINO y NO REPORTA. Los vacíos se representan como SIN DATO.
GRUPO ETARIO	Texto	Grupo etario registrado en el hecho.	ADULTOS	Vacío en 14.811 filas (8,4%); valores: ADULTOS, ADOLESCENTES y MENORES.
TIPO DE HURTO	Texto	Tipo de hurto según la clasificación de la fuente (artículo y modalidad).	ARTÍCULO 239. HURTO ENTIDADES COMERCIALES	Solo dos valores; HURTO RESIDENCIAS aparece desde 2024.
CANTIDAD	Entero	Cantidad reportada en el registro.	1	Sin nulos, negativos ni ceros; vale 1 en todas las filas. Se distingue de COUNT(*).
LOCALIDAD	Texto	Localidad asignada por el equipo al registro (con autorización del docente) para la integración territorial; no es un campo original de la Policía.	Suba	Los nombres llevan tildes y "La Candelaria" frente a "CANDELARIA" en F4; se relacionan con LocCodigo mediante una tabla de equivalencia explícita (20 de 20 nombres, relación uno a uno).

A.3 F3 – Dinámica empresarial (dinamicaempresarial2023/2024/2025.gpkg)

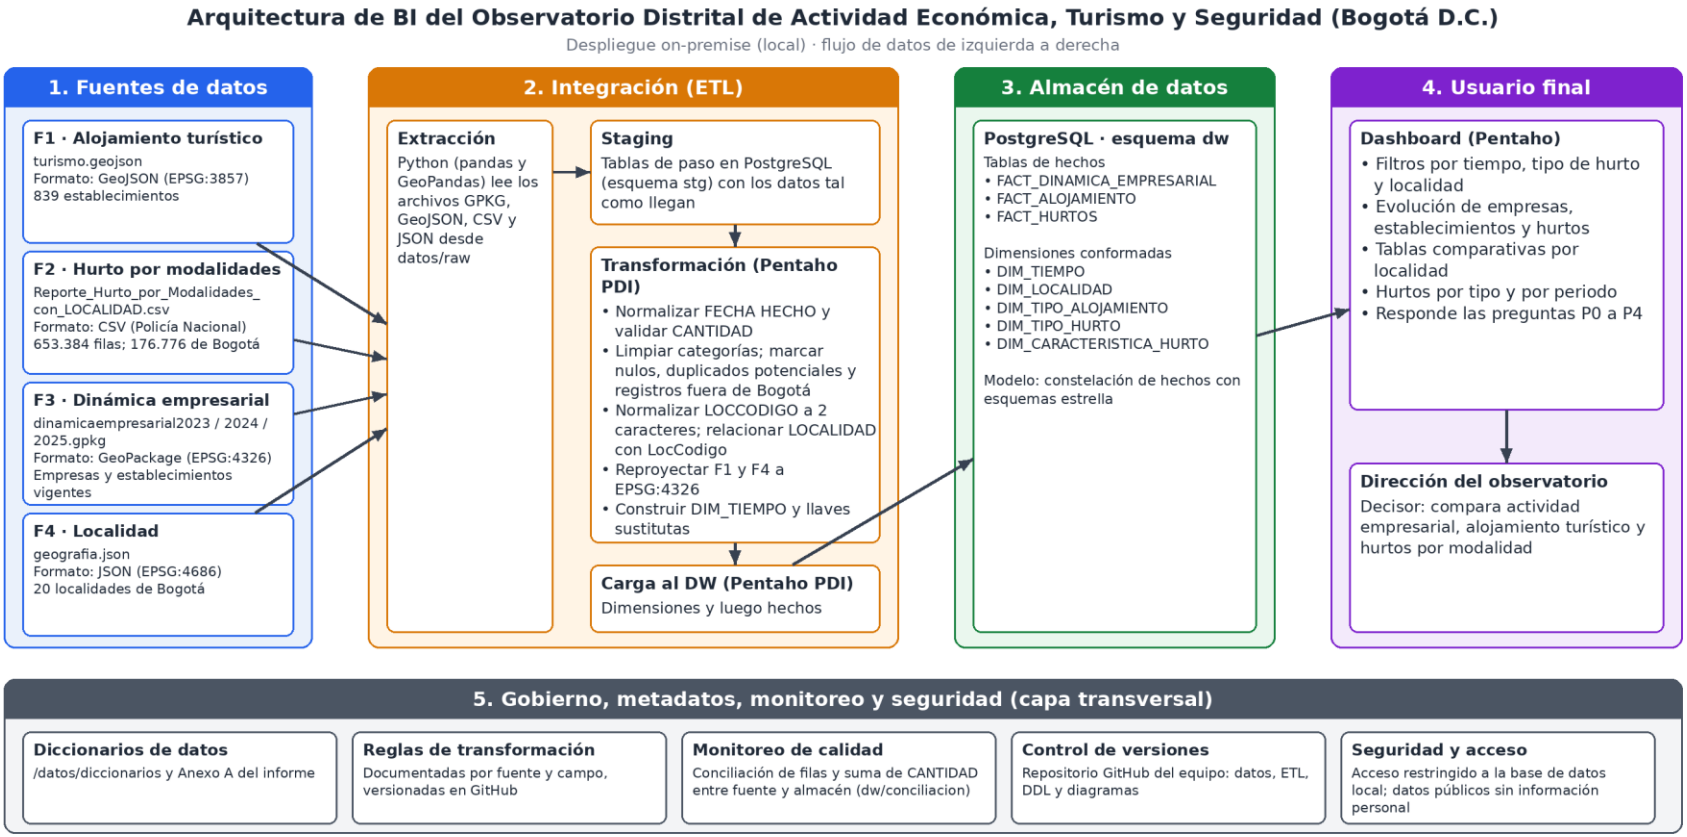
Campo	Tipo	Descripción	Ejemplo	Problema de calidad
Resumen.LOCCODIGO	Texto(2)	Código de la localidad.	01	Correcto en la capa resumen (19 localidades, sin Sumapaz).
Resumen.LOCNOMBRE	Texto	Nombre de la localidad.	USAQUEN	Grafía distinta por año: "USAQUEN" (2023), "Usaquén" (2025).
Resumen.EmpresasVigentes	Entero	Total de empresas con matrícula vigente en la localidad.	39867	—
Resumen.EstablecimientosVigentes	Entero	Total de establecimientos con matrícula vigente en la localidad.	15984	Nulo en las 19 filas de 2023.
Resumen.Periodo	Fecha	Fecha de corte de la información.	2023-09-01	Un solo corte por archivo (sep 2023, mar 2024, jul 2025).
Resumen.identificador	Texto(8)	Llave del registro: código de localidad + año + mes.	01202309	—
Resumen.geom	Multipolígono	Contorno de la localidad (EPSG:4326).	—	—
Empresas.Periodo / Mes	Entero	Año y mes de la información.	2024 / 3	Periodo es entero aquí y fecha en la capa resumen.
Empresas.LOCCODIGO	Entero	Código de la localidad.	15	Pierde el cero a la izquierda; en 2025 no coincide con el código oficial; existe el código 21 ("Sin Localidad").
Empresas.LOCNOMBRE	Texto	Nombre de la localidad.	15	En 2023 y 2024 contiene el código en lugar del nombre.
Empresas.TamanioEmpresarial	Texto	Tamaño de la empresa (Micro, Pequeña, Mediana, Grande).	Grande	"Sin Información" (2023, 2025) y nulos (95 en 2024).
Empresas.RamaActividadEconomica	Texto	Gran rama de actividad económica.	Comercio	—
Empresas.CodigoCIIU	Texto	Código CIIU de la actividad económica.	4751	8 registros vacíos en 2023.
Empresas.OrganizacionJuridica	Texto	Tipo de organización jurídica.	Persona Natural	—
Empresas.empresasvigentes	Entero	Cantidad de empresas vigentes del registro.	1	Nulo en 4.267 de 30.927 filas (2023); cada fila trae solo una de las tres medidas.
Empresas.empresasCreadas / EmpresasCanceladas	Entero	Empresas creadas y canceladas en el periodo.	Nulo	Nulo en 23.198 y 22.478 de 30.927 filas (2023): cada fila trae solo una

Campo	Tipo	Descripción	Ejemplo	Problema de calidad
				de las tres medidas, por lo que el nulo significa "no aplica".
Empresas.SexoRL	Texto	Sexo del representante legal.	Masculino	Nulo en todo 2023; "Indeterminado" en 2024 y 2025.
Establecimientos.Establecimientosvigentes	Entero	Cantidad de establecimientos vigentes del registro (por rama y CIIU).	2	La capa está vacía en 2023: los establecimientos vigentes de 2023 no están disponibles.
Establecimientos.(demás campos)	—	Identificador, Periodo, Mes, LOCNOMBRE, LOCCODIGO, RamaActividadEconomica y CodigoCIIU, con el mismo significado que en Empresas.	—	Mismos problemas de código y nombre de localidad.

A.4 F4 – Localidad (geografia.json). Diccionario elaborado a partir de los datos, porque la fuente no publica uno

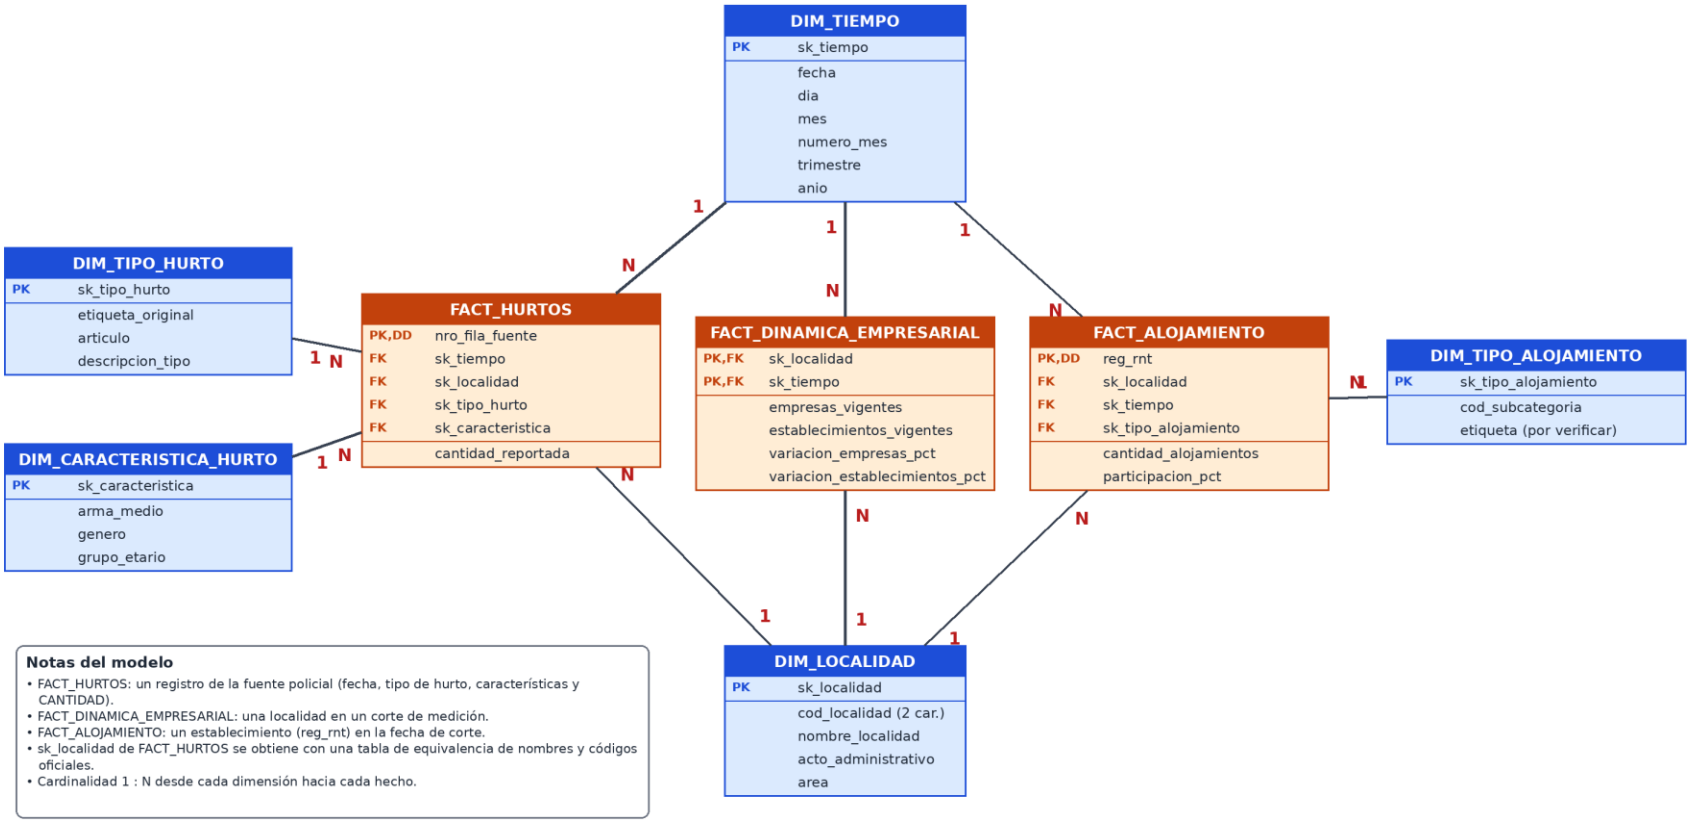
Campo	Tipo	Descripción	Ejemplo	Problema de calidad
OBJECTID	Entero	Identificador del registro.	81	—
LocNombre	Texto	Nombre de la localidad.	ANTONIO NARIÑO	Mayúscula y sin tildes ("USAQUEN", "SANTA FE").
LocAAdmini	Texto	Acto administrativo que crea la localidad.	Acuerdo 117 de 2003	—
LocArea	Decimal	Área de la localidad, en metros cuadrados.	4879543.39	—
LocCodigo	Texto(2)	Identificador único de la localidad, con dos caracteres.	15	Es la llave de referencia para normalizar F1 y F3.
SHAPE_Length / SHAPE_Area	Decimal	Perímetro y área de la geometría.	0.108973 / 0.000397	Unidades en grados (EPSG:4686).
geometry	Polígono	Contorno de la localidad (EPSG:4686).	—	CRS distinto a F1 (3857) y F3 (4326).
Nota	—	Esta dimensión representa las 20 localidades oficiales de Bogotá.	—	Ofrece los códigos oficiales a los que se relaciona, mediante equivalencia explícita, el nombre de localidad de F2.

Anexo B. Diagramas a tamaño completo



Modelo dimensional: constelación de hechos del Observatorio Distrital (Bogotá D.C.)

PK: llave primaria · FK: llave foránea · DD: dimensión degenerada



Notas del modelo

- FACT_HURTOS: un registro de la fuente policial (fecha, tipo de hurto, características y CANTIDAD).
- FACT_DINAMICA_EMPRESARIAL: una localidad en un corte de medición.
- FACT_ALOJAMIENTO: un establecimiento (reg_rnt) en la fecha de corte.
- sk_localidad de FACT_HURTOS se obtiene con una tabla de equivalencia de nombres y códigos oficiales.
- Cardinalidad 1 : N desde cada dimensión hacia cada hecho.