Business Intelligence

Proyecto final · Entrega 2

Data warehouse, ETL y tablero

Observatorio Distrital de Actividad Económica, Turismo y Seguridad de Bogotá D.C.

Integrante	Código
Julian David Avila Cortes	506232041
Santiago Rocha Ramirez	506232712

Dato	Valor
Docente	Leandro Pájaro Fuentes
Fecha de entrega	01/11/2026
Repositorio	https://github.com/SantiagoRR17/bi-proyecto-equipo506232712
Motor de base de datos	PostgreSQL 16
Herramienta del tablero	Power BI Desktop

Resumen de la entrega

Se construyó un data warehouse en PostgreSQL con 8 tablas (5 dimensiones y 3 de hechos) y se cargó con un trabajo de PDI de 8 transformaciones: 176.776 registros en `fact_hurtos`, 839 en `fact_alojamiento` y 60 en `fact_dinamica_empresarial`. La conciliación con las fuentes dio 85 comprobaciones en OK y 0 diferencias.

Respuesta a la pregunta principal (P0), con cifras del tablero: la actividad empresarial de Bogotá bajó entre los cortes de marzo de 2024 y julio de 2025, de 450.376 a 378.759 empresas vigentes (−15,9 %); hay 839 alojamientos en el Registro Nacional de Turismo, concentrados en Teusaquillo (209) y Chapinero (160); y los hurtos suman 176.776 registros entre 2010 y julio de 2026, con un promedio de 888,3 por mes. Las fuentes cubren periodos distintos, por lo que la comparación es descriptiva y no implica causalidad.

1. Modelo físico

El almacén de datos quedó creado en PostgreSQL 16 con 8 tablas: 5 dimensiones y 3 tablas de hechos, y se cargó completo con PDI (176.776 registros en `fact_hurtos`, 839 en `fact_alojamiento` y 60 en `fact_dinamica_empresarial`).

1.1 Motor y base de datos

- **Motor:** PostgreSQL 16, ejecutado en un contenedor Docker local (puerto 5433 del equipo).
- **Base de datos:** `observatorio_bi`.
- **Esquemas:** `dw` (modelo dimensional) y `stg` (tablas auxiliares de la conciliación: `stg.conciliacion_fuente` y `stg.conciliacion_pdi`).
- **Usuario del tablero:** `powerbi_lector`, con permiso solo de lectura (`SELECT`) sobre el esquema `dw`.
- **Claves:** las llaves de las dimensiones son subrogadas (`IDENTITY`); la llave de la fuente se conserva como atributo (por ejemplo `cod_localidad`, `cod_subcategoria`). Cada dimensión tiene un miembro de control con llave `-1` («DESCONOCIDO») para los hechos que no logran asociarse.

1.2 Tablas creadas

El esquema es una constelación: tres tablas de hechos que comparten dimensiones conformadas (`dim_tiempo` y `dim_localidad`). Los registros de las dimensiones incluyen el miembro `-1`, salvo `dim_tiempo`, que no lo tiene.

Tabla	Tipo	Llave primaria	Llaves foráneas	Registros	Script DDL
dim_tiempo	Dimensión	sk_tiempo	—	6.209	dw/ddl/01_crear_modelo_dw.sql
dim_localidad	Dimensión	sk_localidad	—	21 (20 + miembro -1)	dw/ddl/01_crear_modelo_dw.sql
dim_tipo_alojamiento	Dimensión	sk_tipo_alojamiento	—	8 (7 + miembro -1)	dw/ddl/01_crear_modelo_dw.sql
dim_tipo_hurto	Dimensión	sk_tipo_hurto	—	3 (2 + miembro -1)	dw/ddl/01_crear_modelo_dw.sql
dim_caracteristica_hurto	Dimensión	sk_caracteristica	—	69 (68 + miembro -1)	dw/ddl/01_crear_modelo_dw.sql
fact_dinamica_empresarial	Hechos	(sk_localidad, sk_tiempo)	sk_localidad, sk_tiempo	60	dw/ddl/01_crear_modelo_dw.sql

Tabla	Tipo	Llave primaria	Llaves foráneas	Registros	Script DDL
fact_alojamiento	Hechos	reg_rnt	sk_localidad, sk_tiempo, sk_tipo_alojamiento	839	dw/ddl/01_crear_modelo_dw.sql
fact_hurtos	Hechos	nro_fila_fuente	sk_tiempo, sk_localidad, sk_tipo_hurto, sk_caracteristica	176.776	dw/ddl/01_crear_modelo_dw.sql

1.3 Diagrama del modelo físico

El esquema implementado es una **constelación de hechos** (varias estrellas que comparten dimensiones): cada tabla de hechos se une a sus dimensiones por llaves subrogadas, y no hay dimensiones normalizadas en copo de nieve. Coincide con el diagrama de la Entrega 1, sin columnas adicionales.

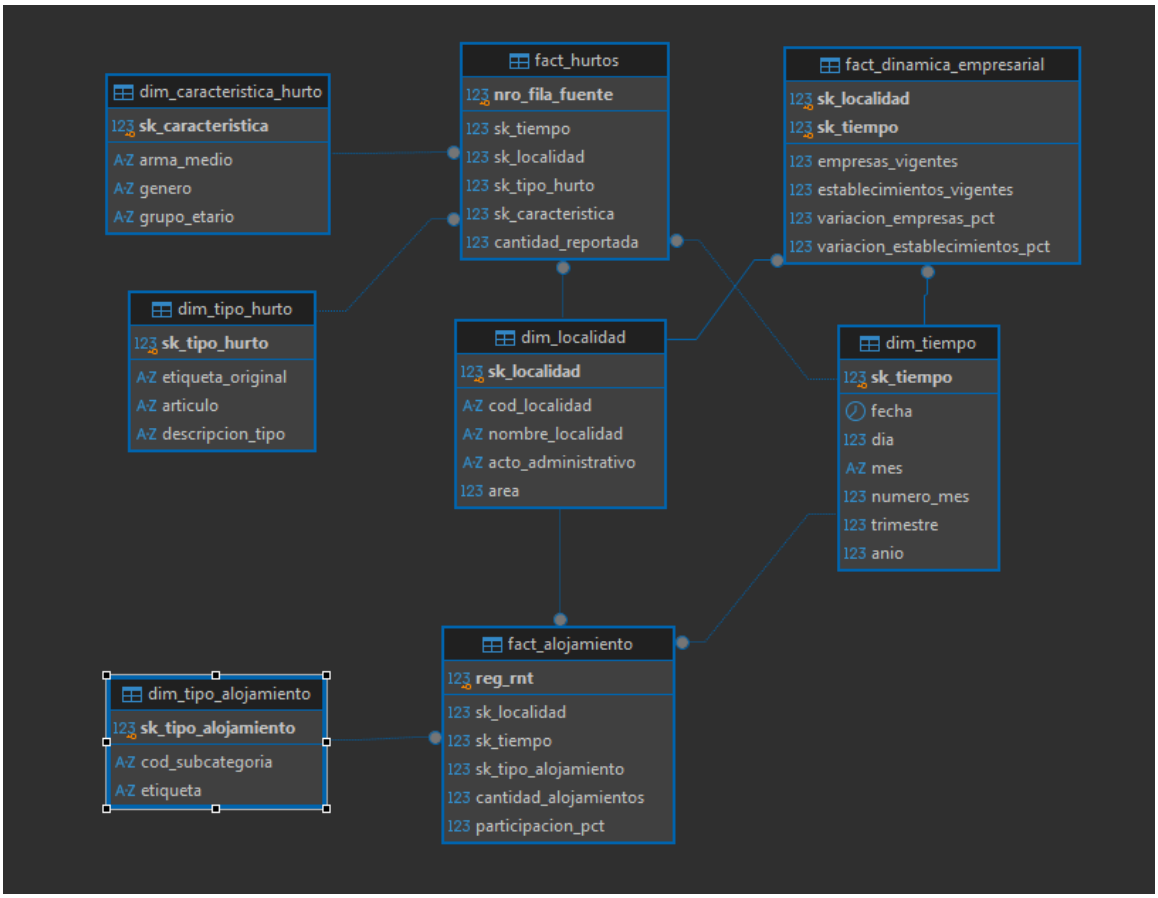


Diagrama ER generado con DBeaver a partir de la base ya creada (esquema `dw`). El archivo PNG se guarda en `docs/diagramas`.

1.4 Dimensión de tiempo

- **Rango:** 01/01/2010 a 31/12/2026, sin huecos: 6.209 días (17 años, 4 de ellos bisiestos).
- **Cómo se pobló:** con la transformación `t_dim_tiempo.ktr`, que genera el calendario diario con `generate_series` de PostgreSQL y lo escribe con *Table output*.
- **Atributos:** `sk_tiempo` (entero AAAAMMDD), `fecha`, `dia`, `mes` (nombre), `numero_mes`, `trimestre` y `anio`. Una restricción comprueba que `sk_tiempo` coincida con la fecha.
- **Cobertura de los hechos:** todos los periodos de las fuentes caen dentro del rango: hurtos del 01/01/2010 al 31/07/2026, cortes de empresas del 01/09/2023, 01/03/2024 y 01/07/2025, y el corte de alojamientos del 22/10/2026.

2. Procesos ETL

El trabajo `j_carga_dw.kjb` ejecuta 8 transformaciones de PDI en orden (primero las dimensiones, al final los hechos) y carga el DW completo en una sola ejecución. Se ejecutó con Pentaho Data Integration 9.4.0.0-343 (Spoon) sin errores.

2.1 Trabajo de carga

Orden de ejecución del trabajo `etl/trabajos/j_carga_dw.kjb`:

1. **Limpiar DW:** borra hechos y dimensiones y conserva los miembros `-1`, de modo que el trabajo se puede repetir.
2. `t_dim_tiempo`
3. `t_dim_localidad`
4. `t_dim_tipo_alojamiento`
5. `t_dim_tipo_hurto`
6. `t_dim_caracteristica_hurto`
7. `t_fact_dinamica_empresarial`
8. `t_fact_alojamiento`
9. `t_fact_hurtos`
10. **Calcular variación % y participación %:** sentencias SQL que llenan `variacion_empresas_pct`, `variacion_establecimientos_pct` (respecto al corte anterior de la misma localidad) y `participacion_pct`.

Las dimensiones van antes que los hechos porque estos resuelven sus llaves con *Database lookup*; si no hay coincidencia, la fila va al miembro `-1`. Las variables de conexión y las rutas (`DB_HOST`, `DB_PORT`, `DB_NAME`, `DB_USER`, `DB_PASSWORD`, `RAIZ_REPO`, `ARCHIVO_HURTOS`, `FECHA_CORTE_TURISMO`) se leen de `kettle.properties`, que no se sube al repositorio.

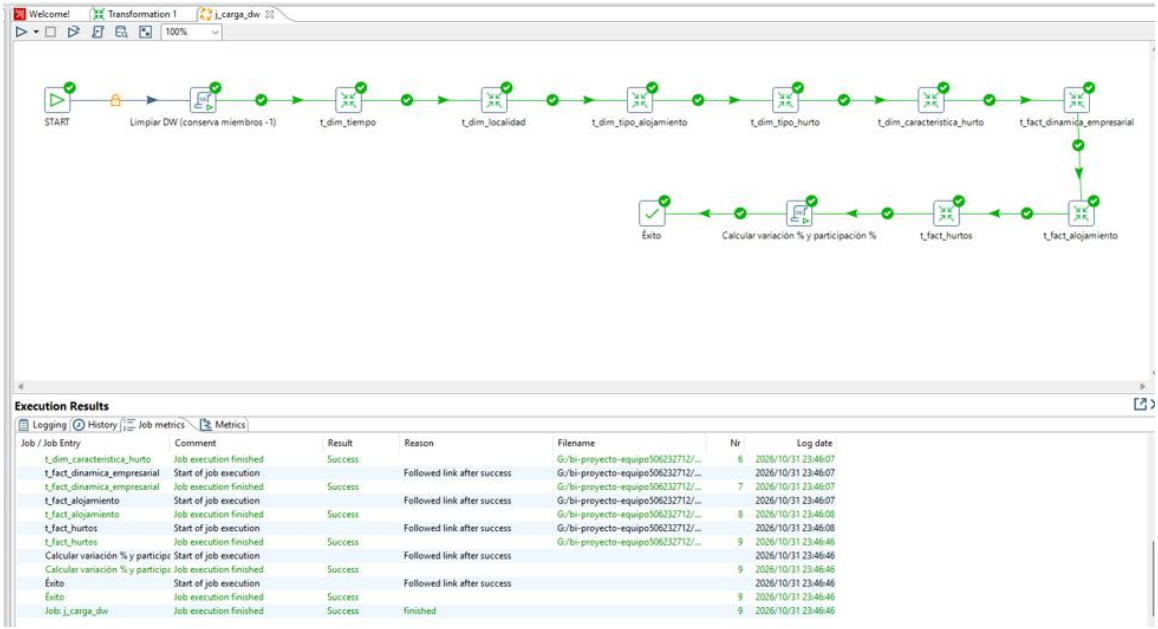


Figura: trabajo `j_carga_dw.kjb` ejecutado en Spoon. Las 10 entradas terminaron en verde (Success) y el trabajo finalizó el 31/10/2026 a las 23:46.

2.2 Transformaciones

Los conteos de la tabla son los del DW cargado, verificados en la conciliación (sección 3). Para F3, *Leídos* cuenta las filas agregadas por localidad y corte: la consulta suma antes las 119.893 filas de la capa `Empresas` y las 12.923 de `Establecimientos`.

Archivo .ktr	Fuente(s) y formato	Destino	Pasos principales	Leídos	Escritos	Rechazos
t_dim_tiempo.ktr	Calendario generado con `generate_series` (PostgreSQL)	dim_tiempo	Table input → Table output	6.209	6.209	0
t_dim_localidad.ktr	F4 `geografia.json` (JSON) y tabla de equivalencia (CSV)	dim_localidad	JSON input → Select values → Stream lookup → Filter rows → Unique rows → Table output	20	20	0
t_dim_tipo_alojamiento.ktr	F1 `turismo.geojson` (JSON)	dim_tipo_alojamiento	JSON input → Modified JavaScript → Unique rows →	839	7	0

Archivo .ktr	Fuente(s) y formato	Destino	Pasos principales	Leídos	Escritos	Rechazos
			Table output			
t_dim_tipo_hurto.ktr	F2 CSV de hurtos con LOCALIDAD	dim_tipo_hurto	CSV input → Select values → Modified JavaScript → Unique rows → Table output	176.776	2	0
t_dim_caracteristica_hurto.ktr	F2 CSV de hurtos con LOCALIDAD	dim_caracteristica_hurto	CSV input → Select values → Modified JavaScript → Unique rows → Table output	176.776	68	0
t_fact_dinamica_empresarial.ktr	F3 tres GeoPackage (`dinamicaempresarial2023/2024/2025.gpkg`, SQLite vía JDBC) y tabla de equivalencia	fact_dinamica_empresarial	Table input (×3) → Select values → Modified JavaScript → Stream lookup → Database lookup → Table output	60	60	0
t_fact_alojamiento.ktr	F1 `turismo.geojson` (JSON) y tabla de equivalencia	fact_alojamiento	JSON input → Modified JavaScript → Stream lookup → Database lookup (×2) → Table output	839	839	0
t_fact_hurtos.ktr	F2 CSV de hurtos con LOCALIDAD y tabla de equivalencia	fact_hurtos	CSV input → Select values → Modified JavaScript → Stream lookup → Database lookup (×3) → Table output	176.776	176.776	0

F2 se lee del CSV que ya contiene solo las 176.776 filas de Bogotá (la columna `LOCALIDAD` se agrega con `etl/scripts/asignar_localidad.py`). Si se usa el CSV completo (653.384 filas), la regla P04 descarta 476.608.

2.3 Reglas de limpieza aplicadas

Los nombres de los pasos empiezan por el código del problema (`P01` a `P15`). Los registros afectados se calcularon directamente de los archivos fuente y se verifican en el log y en *Step Metrics* de la ejecución (detalle en `etl/reglas_calidad.md`).

Problema (Entrega 1)	Fuente y campo	Regla aplicada	Paso de PDI (nombre)	Registros afectados
P01. Código de localidad sin cero a la izquierda	F1.LOCALIDAD	Completar a 2 dígitos («3» → «03») y homologar con la tabla de equivalencia	P01-F1 Completar LOCALIDAD a 2 digitos (3 -> 03)	438 de 839
P02. Dos sistemas de coordenadas	F1.geometría, LATITUD, LONGITUD	Excluir geometría y coordenadas: del alojamiento solo se usa la localidad, así que no hace falta reproyectar	P02-F1 Excluir geometria (EPSG:3857) y LATITUD/LONGITUD; solo se usa LOCALIDAD	839
P03. SUBCATRNT con códigos numéricos; el diccionario usa letras	F1.SUBCATRNT	Conservar el código numérico y dejar `etiqueta` en NULL, sin asignar nombres sin certeza	P03-F1 Conservar codigo numerico SUBCATRNT (sin etiqueta A-Z)	839 filas, 7 códigos (6 a 12)
P04. Hurtos: solo se identifica a Bogotá, no la localidad	F2.DEPARTAMENTO, MUNICIPIO, CODIGO DANE	Filtrar `DEPARTAMENTO = BOGOTA` y verificar municipio y código DANE	P04-F2 Filtrar solo Bogota D.C. (DEPARTAMENTO = BOGOTA)	476.608 descartadas del CSV completo; 176.776 pasan; 0 incoherentes
P05. Fecha como texto dd/mm/aaaa	F2.FECHA HECHO	Convertir a `sk_tiempo` (AAAAMMDD)	P05-F2 Convertir FECHA HECHO (dd/mm/aaaa) a sk_tiempo	0 inválidas (rango 01/01/2010 a 31/07/2026)
P06. Cantidad como texto	F2.CANTIDAD	Validar entero mayor que 0; se conserva `cantidad_reportada`	P06-F2 Validar CANTIDAD entera mayor que 0	0 inválidas; suma 176.776

Problema (Entrega 1)	Fuente y campo	Regla aplicada	Paso de PDI (nombre)	Registros afectados
P07. Género y grupo etario vacíos	F2.GENERO, GRUPO ETARIO	Etiqueta `SIN DATO`; sin imputar categorías	P07-F2 Vacios de genero, grupo etario y arma -> SIN DATO	160.540 de género; 14.811 de grupo etario
P08. Solo dos tipos de hurto; ARMAS MEDIOS incluye NO REPORTADO	F2.TIPO DE HURTO, ARMAS MEDIOS	Separar artículo y descripción; conservar NO REPORTADO como categoría	P08-F2 Tipificar tipo de hurto (articulo + descripcion)	2 tipos en `dim_tipo_hurto`
P09. Localidad: columna añadida, con tildes y «La Candelaria»	F2.LOCALIDAD	Normalizar el nombre y homologar con la tabla de equivalencia (`equivalencia_localidad.csv`)	P09-F2 Homologar LOCALIDAD con tabla de equivalencia	0 sin equivalencia; 8.838 u 8.839 por localidad
P10. Filas que repiten los nueve campos originales	F2 (todos los campos)	No se marcan ni se eliminan: se cuentan en una rama paralela y las 176.776 filas se cargan	P10-F2 Detectar repeticiones de los 9 campos originales (solo conteo)	144.063 repeticiones posibles
P11. Código y nombre de localidad inconsistentes; código 21 «Sin Localidad»	F3.LOCCODIGO, LOCNOMBRE	Agrupar por nombre (el código de 2025 es un índice erróneo) y homologar; 21 y «Sin Localidad» van al miembro -1	P11-F3 Unificar identificador de localidad (codigo o nombre)	20 (2025); 2 (2023 y 2024)
P12. Establecimientos de 2023 sin dato	F3.EstablecimientosVigentes	Conservar NULL; no imputar	P12-F3 Conservar NULL de establecimientos (no imputar)	20
P13. Grafía distinta de nombres y un corte por archivo	F3.LOCNOMBRE, Periodo, Mes	Homologar la grafía con la tabla y tomar el corte del Periodo y Mes	P13-F3 {año} detalle agregado por localidad y corte	20 nombres con grafía distinta (2025); cortes 20230901, 20240301 y

Problema (Entrega 1)	Fuente y campo	Regla aplicada	Paso de PDI (nombre)	Registros afectados
		del archivo	(Periodo/Mes)	20250701
P14. Nombres de F4 en mayúsculas sin tildes	F4.LocNombre	Buscar el nombre en la tabla de equivalencia y validar que resuelva al mismo código	P14-F4 Buscar nombre en tabla de equivalencia	0 rechazados de 20
P15. Sistema de referencia EPSG:4686 y sin diccionario	F4.geometría	Excluir la geometría y conservar solo atributos	P15-F4 Excluir geometria (EPSG:4686) y conservar solo atributos	20

Además hay pasos de control `C-…` que no están en la tabla 2.2 (llaves nulas, duplicados de llave, valores inválidos). Con los datos actuales rechazan 0 filas.

Supuesto de F3: las sumas de `EmpresasVigentes` ignoran los valores nulos de la capa de detalle (4.267, 273 y 1.256 filas nulas en 2023, 2024 y 2025).

2.4 Evidencia de ejecución

El trabajo terminó sin errores y la conciliación posterior dio 85 de 85 comprobaciones en OK (sección 3).

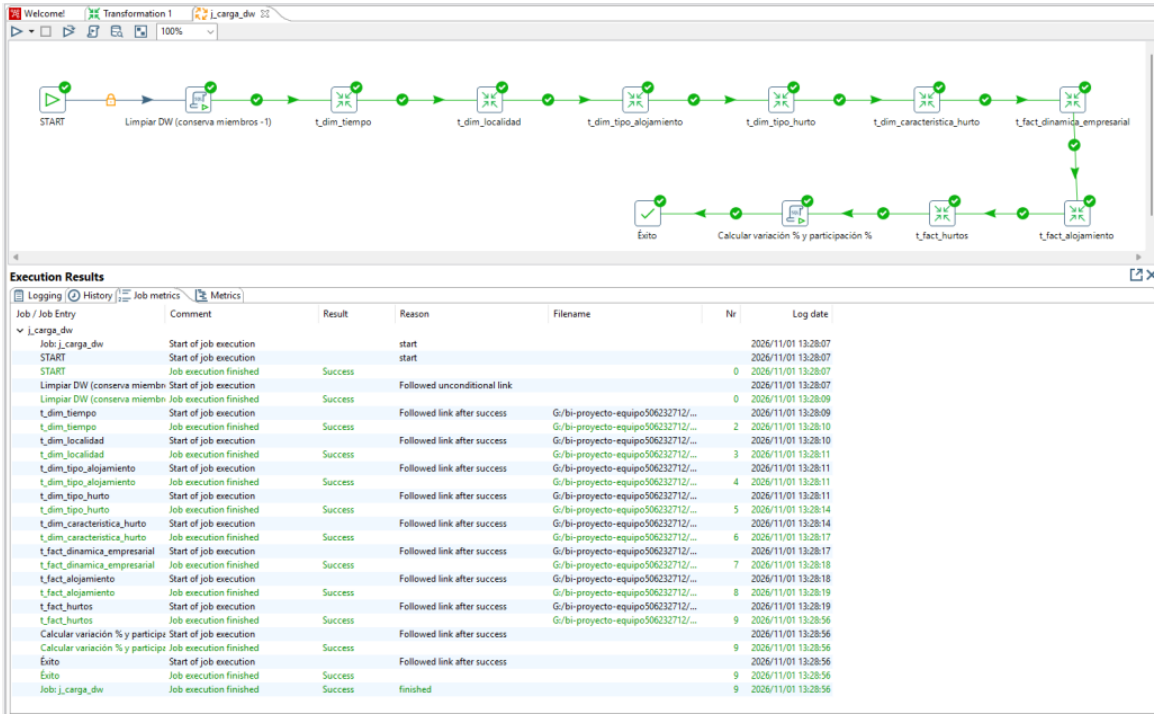


Figura: ejecución completa de `j_carga_dw.kjb` en Spoon, con la pestaña Job metrics. Las ocho transformaciones y el cálculo de variación y participación terminaron en Success.

3. Conciliación

Las 85 comprobaciones de filas y cantidades entre las fuentes y el DW coinciden: 85 en OK y 0 diferencias. Los valores esperados se calcularon con Python directamente de los archivos originales (`dw/conciliacion/generar_valores_fuente.py`), de forma independiente del ETL, y se compararon con las tablas del DW mediante `dw/conciliacion/02_conciliar.sql`.

3.1 Conteo por fuente

Fuente	Leídos	Cargados	Descartados	Motivo de los descartes
F1. Registro Nacional de Turismo (`turismo.geojson`)	839	839	0	No hubo descartes: las 839 filas tienen localidad y subcategoría válidas
F2. Hurtos por modalidades (CSV de la Policía)	653.384	176.776	476.608	Filas de otros departamentos: se filtra `DEPARTAMENTO = BOGOTA` (176.776 filas, 27,1 % del archivo). El trabajo de PDI lee el CSV que ya trae solo Bogotá, y todas sus filas se cargan
F3. Dinámica empresarial (3 GeoPackage)	132.816 filas de detalle (119.893 de `Empresas` y 12.923 de `Establecimientos`)	60	0	No hay descartes. Cambia el grano: el detalle se suma por localidad y corte, lo que da 20 localidades × 3 cortes = 60 filas

3.2 Totales de una métrica

Métrica	Total en la fuente	Total en el DW	Diferencia y explicación
Suma de `CANTIDAD` de hurtos (F2)	176.776	176.776	0. La cantidad es 1 en todas las filas
Filas de hurtos por año, 2010 a 2026 (17 años)	176.776	176.776	0 en cada año (por ejemplo, 2025: 14.281; 2026: 9.173)
Filas de hurtos por localidad (20)	8.839 × 16 + 8.838 × 4	igual	0. Es el reparto equitativo de la `LOCALIDAD` asignada por el

Métrica	Total en la fuente	Total en el DW	Diferencia y explicación
			equipo
Empresas vigentes, corte 2023-09 (F3)	400.077	400.077	0
Empresas vigentes, corte 2024-03 (F3)	450.376	450.376	0
Empresas vigentes, corte 2025-07 (F3)	378.759	378.759	0
Establecimientos vigentes, corte 2024-03 (F3)	257.751	257.751	0
Establecimientos vigentes, corte 2025-07 (F3)	221.444	221.444	0
Establecimientos vigentes, corte 2023-09 (F3)	sin dato	sin dato (20 filas NULL)	La fuente no trae el dato; no se imputa
Alojamientos por localidad y por subcategoría (F1)	839	839	0 en cada una de las 17 localidades con alojamientos y en las 7 subcategorías
Filas de las dimensiones	tiempo 6.209; localidad 20; tipo de alojamiento 7; tipo de hurto 2; característica 68	igual	0 (sin contar los miembros -1)

Controles de integridad. Los hechos de hurtos y de alojamientos no tienen ninguna llave en `-1`. Lo que sí queda en `-1` se explica por las fuentes:

- 3 filas de `fact_dinamica_empresarial` (una por corte) corresponden al código 21 «Sin Localidad» de F3.
- 20 filas de esa misma tabla tienen establecimientos NULL: el corte de 2023 no los trae.
- 3 localidades no tienen alojamientos en F1 (San Cristóbal, Ciudad Bolívar y Sumapaz), y 1 no tiene dinámica empresarial. Es una característica de la fuente, no un error de carga.

Las consultas completas están en el Anexo A y en `dw/conciliacion/`.

4. Tablero

El tablero de Power BI Desktop tiene 5 páginas y usa solo las tablas `dim_*` y `fact_*` del esquema `dw`, en modo importación, conectado con el usuario de solo lectura `powerbi_lector` (`127.0.0.1:5433`, base

observatorio_bi). Las relaciones van de cada hecho hacia sus dimensiones, de muchos a uno y con filtro en una sola dirección. Las medidas DAX están en dashboard/medidas.dax.

4.1 Indicadores

Cada indicador se muestra frente a una referencia (periodo anterior o promedio histórico). Las cifras de la tabla son las del tablero sin filtros y coinciden con las consultas de dashboard/consultas_tablero.sql.

Indicador	Fórmula (DAX)	Qué mide	Referencia	Pregunta
Empresas vigentes (379 mil)	`CALCULATE ( SUM ( fact_dinamica_empresarial[empresas_vigentes] ), fact_dinamica_empresarial[sk_tiempo] = MAX ( fact_dinamica_empresarial[sk_tiempo] ) )`	Empresas vigentes en el último corte (julio de 2025): 378.759	Corte anterior (marzo de 2024): 450.376; variación −15,9 %	P0, P1
Establecimientos vigentes (221 mil)	Igual que el anterior, con `establecimientos_vigentes`	Establecimientos vigentes en el último corte: 221.444	Corte anterior: 257.751; variación −14,1 % (2023 no tiene dato en la fuente)	P0, P1
Promedio mensual de hurtos	`DIVIDE ( [Hurtos registros], COUNTROWS ( FILTER ( VALUES ( dim_tiempo[MesKey] ), [Hurtos registros] > 0 ) ) )`	Registros de hurto por mes con datos: 888,3	Promedio histórico (888,3); al filtrar un año se compara con él (2025: +34,0 %)	P0, P3
Alojamientos inscritos en el RNT	`COUNTROWS ( fact_alojamiento )`	Establecimientos de alojamiento turístico: 839	Promedio por localidad con alojamientos: 49,4	P0, P2

Las variaciones son `DIVIDE ( [Empresas vigentes] - [Empresas corte anterior], [Empresas corte anterior] )` y equivalentes. El corte anterior se calcula con `REMOVEFILTERS ( dim_tiempo )` para que no dependa del segmentador de año.

4.2 Respuesta a las preguntas de negocio

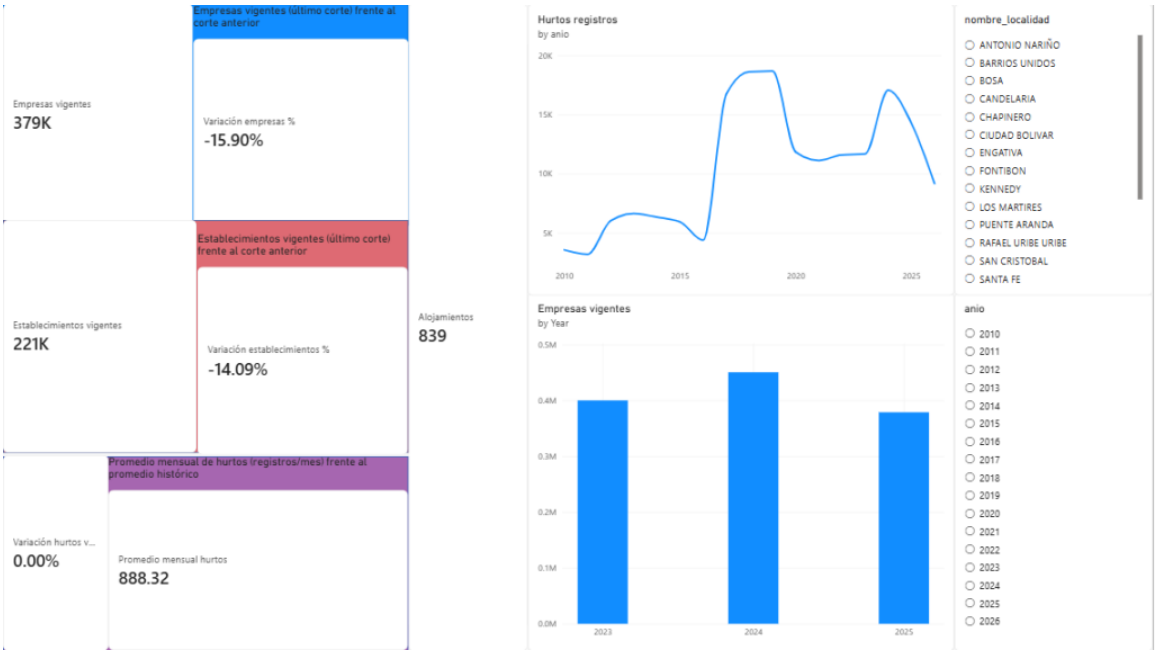
Pregunta	Página y visual	Tipo de gráfico y por qué	Respuesta encontrada (con cifra)
P0. Distribución y evolución de la actividad	Página 1 «Panorama de Bogotá»: tres	Indicadores con referencia (una cifra y su	Las empresas vigentes bajaron de 450.376 (marzo de 2024) a 378.759 (julio de 2025), −15,9 %; los

Pregunta	Página y visual	Tipo de gráfico y por qué	Respuesta encontrada (con cifra)
empresarial, los alojamientos y los hurtos en Bogotá	indicadores, tarjeta de alojamientos, línea de hurtos y columnas de empresas por corte	cambio), línea para la serie anual de hurtos y columnas para tres cortes puntuales	establecimientos, de 257.751 a 221.444 (−14,1 %). Hay 839 alojamientos en el RNT (corte de octubre de 2026) y 176.776 registros de hurto entre 2010 y julio de 2026, con un promedio de 888,3 por mes
P1. Localidades con más empresas y establecimientos y su evolución entre cortes	Página 2: barras de empresas por localidad, columnas agrupadas por corte y tabla con variación	Barras ordenadas (ranking de una medida entre localidades), columnas por corte (tres puntos, no una serie continua) y tabla para comparar dos medidas	Suba lidera con 46.228 empresas y 22.882 establecimientos, seguida de Usaquén (38.307), Chapinero (36.815), Kennedy (36.587) y Engativá (32.896). Todas las localidades bajaron entre cortes (de −6,2 % a −22,2 %); la mayor caída es San Cristóbal (−22,2 %)
P2. Distribución de los alojamientos por localidad y subcategorías representadas	Página 3: barras de alojamientos por localidad con línea de promedio y barras por código de subcategoría	Barras horizontales: categorías nominales sin orden natural; la línea de promedio da la referencia	Teusaquillo concentra 209 alojamientos y Chapinero 160, frente a un promedio de 49,4 por localidad. La subcategoría 9 agrupa 668 de los 839 (79,6 %). Tres localidades no tienen alojamientos en la fuente (San Cristóbal, Ciudad Bolívar y Sumapaz)
P3. Evolución de registros y cantidades de hurto por fecha, tipo y otras características	Página 4: línea anual, columnas por tipo de hurto, barras por arma o medio, columnas por grupo etario y género, y barras por localidad	Línea para la evolución temporal; barras y columnas para comparar categorías	Los registros pasan de 3.554 (2010) a un máximo de 18.690 (2019), bajan a 11.841 en 2020 y suben a 17.071 en 2024; 2025 cierra en 14.281 y 2026 (enero a julio) lleva 9.173. Predomina el hurto a entidades comerciales; la mayor parte de los hechos son sin empleo de armas. El género es «SIN DATO» en 160.540 filas (90,8 %)
P4. Comparación descriptiva de empresas,	Página 5: líneas de índice base 2023 = 100 y	Índice con base común para poner en la	Entre 2023 y 2025 el índice de empresas sube a 112,6 en 2024 y cae a 94,7 en 2025; el de hurtos sube a 146,4

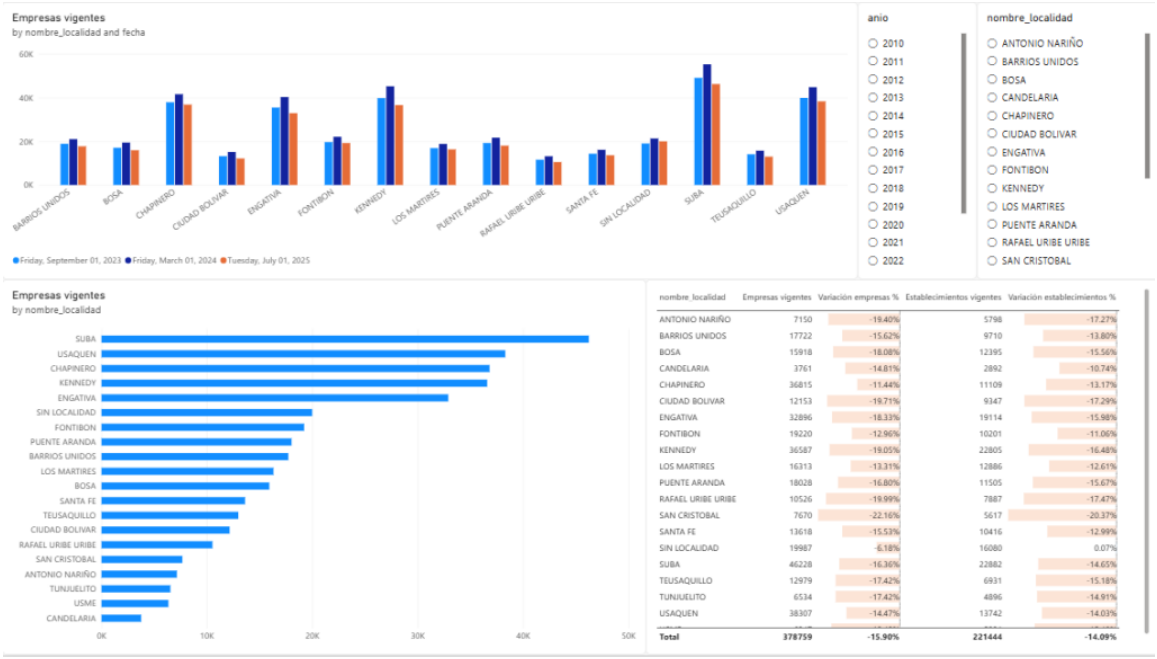
Pregunta	Página y visual	Tipo de gráfico y por qué	Respuesta encontrada (con cifra)
alojamiento y hurtos sin inferir causalidad	tabla comparativa por localidad	misma escala magnitudes distintas (cortes puntuales de empresas y años completos de hurtos)	en 2024 y queda en 122,4 en 2025. Son series descriptivas: no se concluye que una explique la otra

4.3 Capturas del tablero

Página 1 · Panorama de Bogotá (P0)

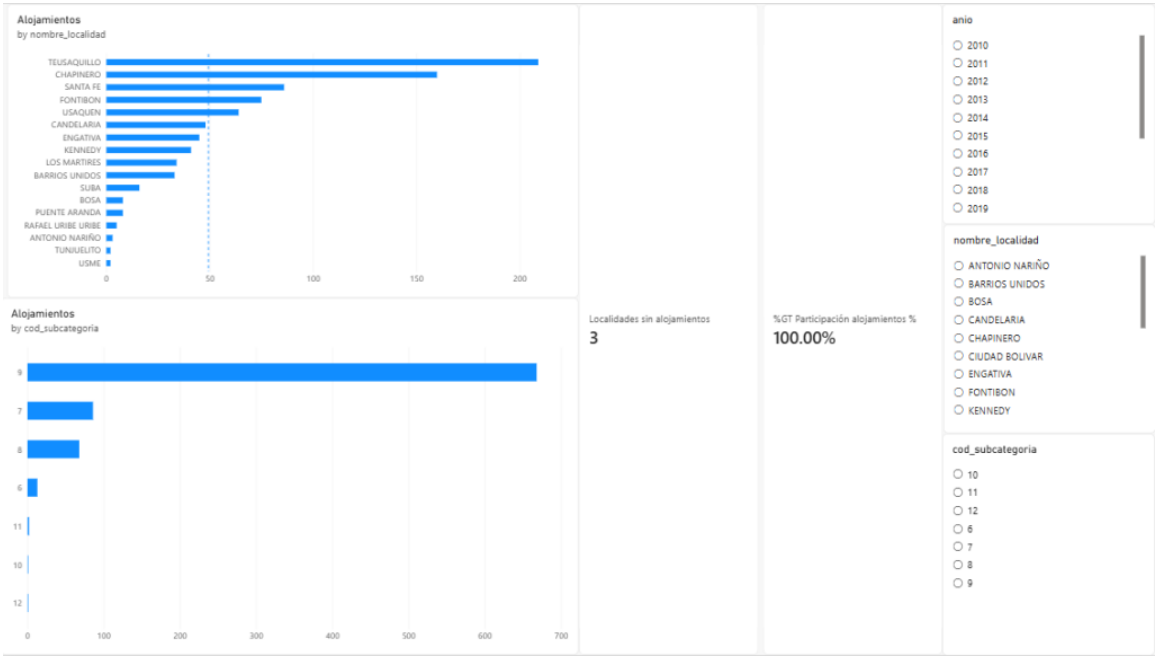


Página 2 · Actividad empresarial por localidad (P1)

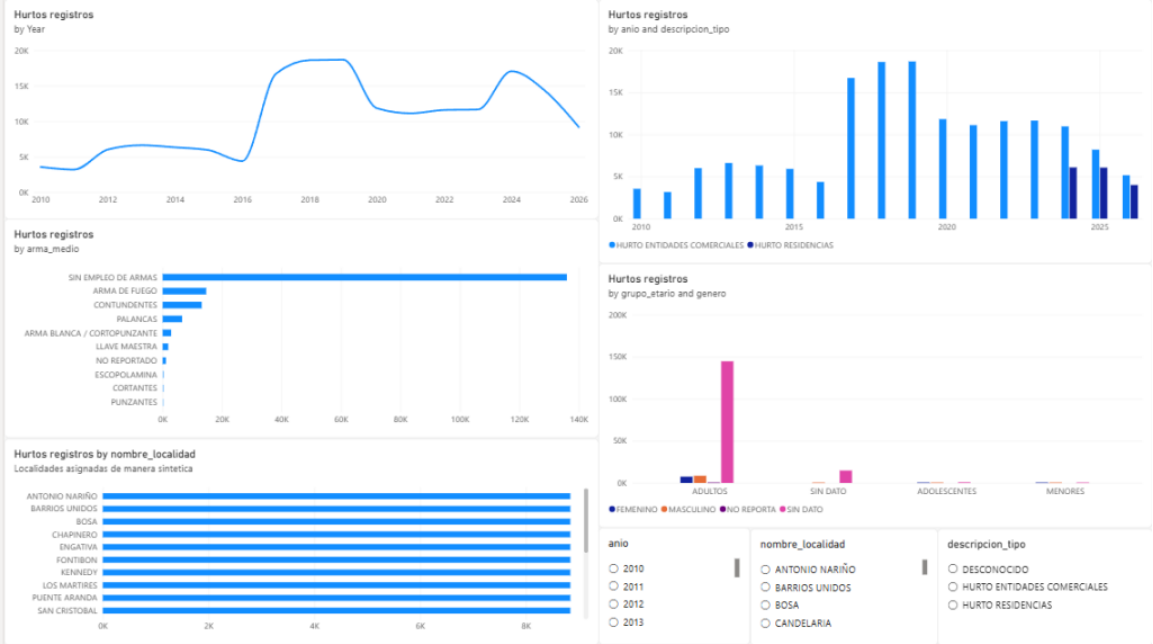


nombre_localidad	Empresas vigentes	Variación empresas %	Establecimientos vigentes	Variación establecimientos %
ANTONIO NARIÑO	7150	-19.40%	5798	-17.27%
BARRIOS UNIDOS	17722	-15.62%	9710	-13.80%
BOSA	15918	-18.08%	12395	-15.56%
CANDELARIA	3761	-14.81%	2892	-10.74%
CHAPINERO	36815	-11.44%	11109	-13.17%
CIUDAD BOLIVAR	12153	-19.71%	9347	-17.29%
ENGATIVA	32896	-18.33%	19114	-15.98%
FONTIBON	19220	-12.96%	10201	-11.06%
KENNEDY	36587	-19.05%	22805	-16.48%
LOS MARTIRES	16313	-13.31%	12886	-12.61%
PUENTE ARANDA	18028	-16.80%	11505	-15.67%
RAFAEL URIBE URIBE	10526	-19.99%	7887	-17.47%
SAN CRISTOBAL	7670	-22.16%	5617	-20.37%
SANTA FE	13618	-15.53%	10416	-12.99%
SIN LOCALIDAD	19987	-6.18%	16080	0.07%
SUBA	46228	-16.36%	22882	-14.65%
TEUSAQUILLO	12979	-17.42%	6931	-15.18%
TUNJUELITO	6534	-17.42%	4896	-14.91%
USAQUEN	38307	-14.47%	13742	-14.03%
Total	**378759**	**-15.90%**	**221444**	**-14.09%**

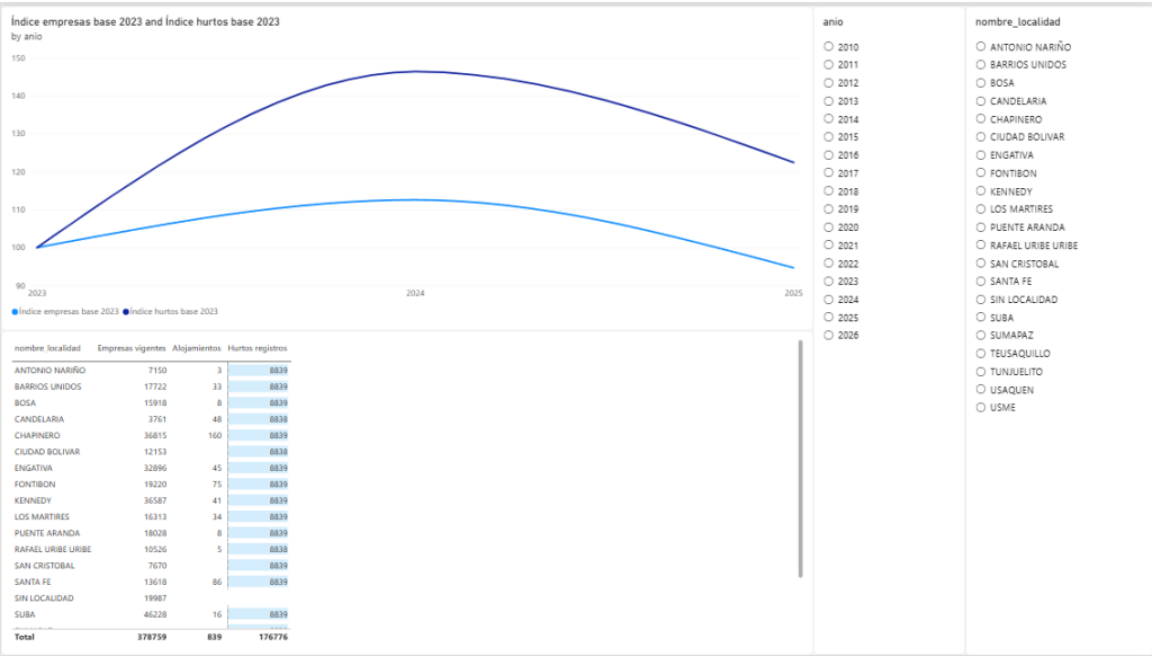
Página 3 · Alojamiento turístico por localidad (P2)



Página 4 · Hurtos por modalidades (P3)



Página 5 · Comparación descriptiva (P4)



4.4 Filtros

Segmentador	Campo	Páginas en las que actúa	Observación
Año	`dim_tiempo[anio]`	1, 2, 3, 4	Tiempo. En la página 3 solo 2026 devuelve datos (la fuente de alojamientos tiene un

Segmentador	Campo	Páginas en las que actúa	Observación
		y 5	solo corte); empresas solo tiene datos en 2023, 2024 y 2025
Localidad	`dim_localidad[nombre_localidad]`	1, 2, 3, 4 y 5	Incluye «SIN LOCALIDAD» (código 21 de F3)
Subcategoría	`dim_tipo_alojamiento[cod_subcategoria]`	3	Se muestra el código original de SUBCATRNT; el diccionario no permite verificar los nombres
Tipo de hurto	`dim_tipo_hurto[descripcion_tipo]`	4	Incluye el miembro de control «DESCONOCIDO», sin registros

Advertencias que se declaran en el tablero y en este informe:

- La `LOCALIDAD` de los hurtos fue asignada por el equipo de forma simulada y equitativa (8.838 u 8.839 filas por localidad), con autorización del docente. Cualquier cifra de hurtos por localidad refleja ese reparto, no la realidad.
- Los cortes de F3 (septiembre de 2023, marzo de 2024 y julio de 2025) no son continuos ni equidistantes.
- 2026 es parcial en hurtos (enero a julio).
- Los hurtos incluyen repeticiones posibles de los nueve campos originales (144.063 filas): no se marcaron ni se eliminaron, de modo que `COUNT(*)` las incluye.
- No se cargan coordenadas de los alojamientos: del alojamiento solo se usa la localidad.

Anexos

Anexo A. Consultas de conciliación

Las consultas de la sección 3 son las de `/dw/conciliacion`. Orden de ejecución, conectado a `observatorio_bi` después de correr el trabajo de PDI:

1. `python dw/conciliacion/generar_valores_fuente.py` calcula los valores esperados de los archivos originales y escribe `01_valores_fuente.sql` (107 valores).
2. `00_tabla_conteos_pdi.sql` crea `stg.conciliacion_pdi`.
3. `01_valores_fuente.sql` carga `stg.conciliacion_fuente`.
4. `02_conciliar.sql` compara lo esperado con lo cargado. Se muestran sus consultas principales (valores del DW, sección 1 y resumen).

```
-- Valores que quedaron en el DW, con los mismos nombres de concepto que
stg.conciliacion_fuente
CREATE TEMP TABLE dw_vals AS
SELECT 'F1'::text AS fuente, 'cmp_filas_total'::text AS concepto, ''::text AS clave,
COUNT(*)::numeric AS valor FROM dw.fact_alojamiento
```

```
UNION ALL SELECT 'F1', 'cmp_filas_localidad', l.cod_localidad, COUNT(*) FROM
dw.fact_alojamiento f JOIN dw.dim_localidad l USING (sk_localidad)
          WHERE l.sk_localidad <> -1 GROUP BY l.cod_localidad
UNION ALL SELECT 'F1', 'cmp_filas_subcategoria', t.cod_subcategoria, COUNT(*) FROM
dw.fact_alojamiento f JOIN dw.dim_tipo_alojamiento t USING (sk_tipo_alojamiento)
          WHERE t.sk_tipo_alojamiento <> -1 GROUP BY t.cod_subcategoria
UNION ALL SELECT 'F2', 'cmp_filas_total', '', COUNT(*) FROM dw.fact_hurtos
UNION ALL SELECT 'F2', 'cmp_suma_cantidad', '', SUM(cantidad_reportada) FROM
dw.fact_hurtos
UNION ALL SELECT 'F2', 'cmp_filas_anio', t.anio::text, COUNT(*) FROM dw.fact_hurtos f
JOIN dw.dim_tiempo t USING (sk_tiempo) GROUP BY t.anio
UNION ALL SELECT 'F2', 'cmp_filas_localidad', l.cod_localidad, COUNT(*) FROM
dw.fact_hurtos f JOIN dw.dim_localidad l USING (sk_localidad)
          WHERE l.sk_localidad <> -1 GROUP BY l.cod_localidad
UNION ALL SELECT 'F3', 'cmp_filas_total', '', COUNT(*) FROM
dw.fact_dinamica_empresarial
UNION ALL SELECT 'F3', 'cmp_empresas_corte', sk_tiempo::text, SUM(empresas_vigentes)
FROM dw.fact_dinamica_empresarial GROUP BY sk_tiempo
UNION ALL SELECT 'F3', 'cmp_establecimientos_corte', sk_tiempo::text,
SUM(establecimientos_vigentes) FROM dw.fact_dinamica_empresarial GROUP BY sk_tiempo
UNION ALL SELECT 'DIM', 'cmp_dim_tiempo', '', COUNT(*) FROM dw.dim_tiempo;
-- (el archivo completo incluye también género y grupo etario sin dato, filas por
corte, nulos y las demás dimensiones)

-- 1) Leídos = cargados + descartados (F1 y F2)
WITH f AS (SELECT fuente, concepto, clave, valor FROM stg.conciliacion_fuente),
flujo AS (
  SELECT x.fuente,
         (SELECT valor FROM f WHERE fuente = x.fuente AND concepto = 'info_leidas')
AS leidas,
         COALESCE((SELECT SUM(valor) FROM f WHERE fuente = x.fuente AND concepto LIKE
'info\_descartadas\_%'), 0) AS descartadas,
         (SELECT valor FROM dw_vals WHERE fuente = x.fuente AND concepto =
'cmp_filas_total') AS cargadas_dw
    FROM (VALUES ('F1'), ('F2')) AS x(fuente)
)
SELECT fuente, leidas, descartadas, leidas - descartadas AS esperadas_cargadas,
cargadas_dw,
       cargadas_dw - (leidas - descartadas) AS diferencia,
       CASE WHEN cargadas_dw = leidas - descartadas THEN 'OK' ELSE 'DIFERENCIA' END
AS estado
  FROM flujo ORDER BY fuente;

-- 2) Esperado (fuente) frente a cargado (DW)
CREATE TEMP TABLE comparacion AS
SELECT COALESCE(s.fuente, d.fuente) AS fuente, COALESCE(s.concepto, d.concepto) AS
concepto,
       COALESCE(s.clave, d.clave, '') AS clave, s.valor AS esperado_fuente, d.valor
AS cargado_dw,
       CASE WHEN s.valor IS NOT DISTINCT FROM d.valor THEN 'OK' ELSE 'DIFERENCIA' END
AS estado
  FROM (SELECT * FROM stg.conciliacion_fuente WHERE concepto LIKE 'cmp\_%') s
  FULL JOIN (SELECT fuente, concepto, COALESCE(clave, '') AS clave, valor FROM
dw_vals) d
    ON d.fuente = s.fuente AND d.concepto = s.concepto AND d.clave = s.clave;
```

```
-- 3) Resumen
SELECT COUNT(*) AS comprobaciones, COUNT(*) FILTER (WHERE estado = 'OK') AS ok,
       COUNT(*) FILTER (WHERE estado <> 'OK') AS diferencias,
       CASE WHEN COUNT(*) FILTER (WHERE estado <> 'OK') = 0 THEN 'CONCILIACION OK'
ELSE 'REVISAR DIFERENCIAS' END AS resultado
  FROM comparacion;
```

Resultado de la ejecución (salida completa en `/evidencia/salida_02_conciliar.txt`):

Fuente	Leídas	Descartadas	Esperadas cargadas	Cargadas en el DW	Diferencia	Estado
F1	839	0	839	839	0	OK
F2	176.776	0	176.776	176.776	0	OK

Comprobaciones	OK	Diferencias	Resultado
85	85	0	CONCILIACION OK

Controles de integridad (sección 5 de `02_conciliar.sql`):

Control	Filas
fact_hurtos con localidad, tipo de hurto o característica en -1	0
fact_alojamiento con localidad o tipo en -1	0
fact_dinamica_empresarial con localidad -1 (código 21 «Sin Localidad»)	3
fact_dinamica_empresarial con establecimientos NULL (2023 sin dato)	20
Localidades sin ningún hurto	0
Localidades sin ningún alojamiento	3
Localidades sin dinámica empresarial	1

Anexo B. Capturas adicionales

Salida de `03_verificar_modelo.sql` (tabla 1.2). Las 8 tablas tienen llave primaria, los hechos tienen 3, 2 y 4 llaves foráneas y los conteos coinciden con los de la sección 1.2. Llaves foráneas verificadas en el catálogo de PostgreSQL:

Tabla de hechos	Columna	Dimensión referenciada	Restricción
fact_dinamica_empresarial	sk_localidad	dim_localidad	fk_fact_dinamica_localidad
fact_dinamica_empres	sk_tiempo	dim_tiempo	fk_fact_dinamica_tiem

Tabla de hechos	Columna	Dimensión referenciada	Restricción
arial			po
fact_alojamiento	sk_localidad	dim_localidad	fk_fact_alojamiento_localidad
fact_alojamiento	sk_tiempo	dim_tiempo	fk_fact_alojamiento_tiempo
fact_alojamiento	sk_tipo_alojamiento	dim_tipo_alojamiento	fk_fact_alojamiento_tipo
fact_hurtos	sk_caracteristica	dim_caracteristica_hurto	fk_fact_hurtos_caracteristica
fact_hurtos	sk_localidad	dim_localidad	fk_fact_hurtos_localidad
fact_hurtos	sk_tiempo	dim_tiempo	fk_fact_hurtos_tiempo
fact_hurtos	sk_tipo_hurto	dim_tipo_hurto	fk_fact_hurtos_tipo

La salida completa (41 columnas con su tipo y si admiten nulos, más los registros por tabla) va en `/evidencia/salida_03_verificar_modelo.txt`.

Vista de relaciones del modelo en Power BI. Cada hecho se une a sus dimensiones de muchos a uno (`*` hacia `1`), con filtro en una sola dirección; `dim_tiempo` y `dim_localidad` se comparten entre los tres hechos. `MesKey` es la columna calculada de `dim_tiempo` usada por las medidas.


fact_dinamica_empresar...
empresas_vigentes
establecimientos_vigentes
sk_localidad
sk_tiempo
variacion_empresas_pct
variacion_establecimientos_pct
dim_tiempo
anio
dia
fecha
mes
MesKey
numero_mes
sk_tiempo
fact_alojamiento
cantidad_alojamientos
participacion_pct
reg_mt
sk_localidad
sk_tiempo
sk_tipo_alojamiento
dim_tipo_alojamiento
cod_subcategoria
etiqueta
sk_tipo_alojamiento
dim_tipo_hurto
articulo
descripcion_tipo
etiqueta_original
sk_tipo_hurto
fact_hurtos
cantidad_reportada
nro_fila_fuente
sk_caracteristica
sk_localidad
sk_tiempo
sk_tipo_hurto
dim_caracteristica_hurto
arma_medio
genero
grupo_etario
sk_caracteristica
dim_localidad
acto_administrativo
area
cod_localidad
nombre_localidad
sk_localidad