Business Intelligence

Proyecto final · Entrega 2

Data warehouse, ETL y tablero

Observatorio Distrital de Actividad Económica, Turismo y Seguridad de Bogotá D.C.

Integrante	Código
Julian David Avila Cortes	506232041
Santiago Rocha Ramirez	506232712

Dato	Valor
Docente	Leandro Pájaro Fuentes
Fecha de entrega	01/11/2026 (confirmar con la fecha real de entrega)
Repositorio	https://github.com/SantiagoRR17/bi-proyecto-equipo506232712
Motor de base de datos	PostgreSQL 16
Herramienta del tablero	Power BI Desktop

Resumen de la entrega

Se construyó un data warehouse en PostgreSQL con 8 tablas (5 dimensiones y 3 de hechos) y se cargó con un trabajo de PDI de 8 transformaciones: 176.776 registros en `fact_hurtos`, 839 en `fact_alojamiento` y 60 en `fact_dinamica_empresarial`. La conciliación con las fuentes dio 85 comprobaciones en OK y 0 diferencias.

Respuesta a la pregunta principal (P0), con cifras del tablero: la actividad empresarial de Bogotá bajó entre los cortes de marzo de 2024 y julio de 2025, de 450.376 a 378.759 empresas vigentes (−15,9 %); hay 839 alojamientos en el Registro Nacional de Turismo, concentrados en Teusaquillo (209) y Chapinero (160); y los hurtos suman 176.776 registros entre 2010 y julio de 2026, con un promedio de 888,3 por mes. Las fuentes cubren periodos distintos, por lo que la comparación es descriptiva y no implica causalidad.

1. Modelo físico

El almacén de datos quedó creado en PostgreSQL 16 con 8 tablas: 5 dimensiones y 3 tablas de hechos, y se cargó completo con PDI (176.776 registros en `fact_hurtos`, 839 en `fact_alojamiento` y 60 en `fact_dinamica_empresarial`).

1.1 Motor y base de datos

- **Motor:** PostgreSQL 16, ejecutado en un contenedor Docker local (puerto 5433 del equipo).
- **Base de datos:** `observatorio_bi`.
- **Esquemas:** `dw` (modelo dimensional) y `stg` (tablas auxiliares de la conciliación: `stg.conciliacion_fuente` y `stg.conciliacion_pdi`).
- **Usuario del tablero:** `powerbi_lector`, con permiso solo de lectura (`SELECT`) sobre el esquema `dw`.
- **Claves:** las llaves de las dimensiones son subrogadas (`IDENTITY`); la llave de la fuente se conserva como atributo (por ejemplo `cod_localidad`, `cod_subcategoria`). Cada dimensión tiene un miembro de control con llave `-1` («DESCONOCIDO») para los hechos que no logran asociarse.

1.2 Tablas creadas

El esquema es una constelación: tres tablas de hechos que comparten dimensiones conformadas (`dim_tiempo` y `dim_localidad`). Los registros de las dimensiones incluyen el miembro `-1`, salvo `dim_tiempo`, que no lo tiene.

Tabla	Tipo	Llave primaria	Llaves foráneas	Registros	Script DDL
dim_tiempo	Dimensión	sk_tiempo	—	6.209	dw/ddl/01_crear_modelo_dw.sql
dim_localidad	Dimensión	sk_localidad	—	21 (20 + miembro -1)	dw/ddl/01_crear_modelo_dw.sql
dim_tipo_alojamiento	Dimensión	sk_tipo_alojamiento	—	8 (7 + miembro -1)	dw/ddl/01_crear_modelo_dw.sql
dim_tipo_hurto	Dimensión	sk_tipo_hurto	—	3 (2 + miembro -1)	dw/ddl/01_crear_modelo_dw.sql
dim_caracteristica_hurto	Dimensión	sk_caracteristica	—	69 (68 + miembro -1)	dw/ddl/01_crear_modelo_dw.sql
fact_dinamica_empresarial	Hechos	(sk_localidad, sk_tiempo)	sk_localidad, sk_tiempo	60	dw/ddl/01_crear_modelo_dw.sql

Tabla	Tipo	Llave primaria	Llaves foráneas	Registros	Script DDL
fact_alojamiento	Hechos	reg_rnt	sk_localidad, sk_tiempo, sk_tipo_alojamiento	839	dw/ddl/01_crear_modelo_dw.sql
fact_hurtos	Hechos	nro_fila_fuente	sk_tiempo, sk_localidad, sk_tipo_hurto, sk_caracteristica	176.776	dw/ddl/01_crear_modelo_dw.sql

Los miembros `-1` se crean con `dw/ddl/02_filas_desconocido.sql`, y las consultas que sirven para llenar esta tabla están en `dw/ddl/03_verificar_modelo.sql`.

1.3 Diagrama del modelo físico

El esquema implementado es una **constelación de hechos** (varias estrellas que comparten dimensiones): cada tabla de hechos se une a sus dimensiones por llaves subrogadas, y no hay dimensiones normalizadas en copo de nieve. Coincide con el diagrama de la Entrega 1, sin columnas adicionales.

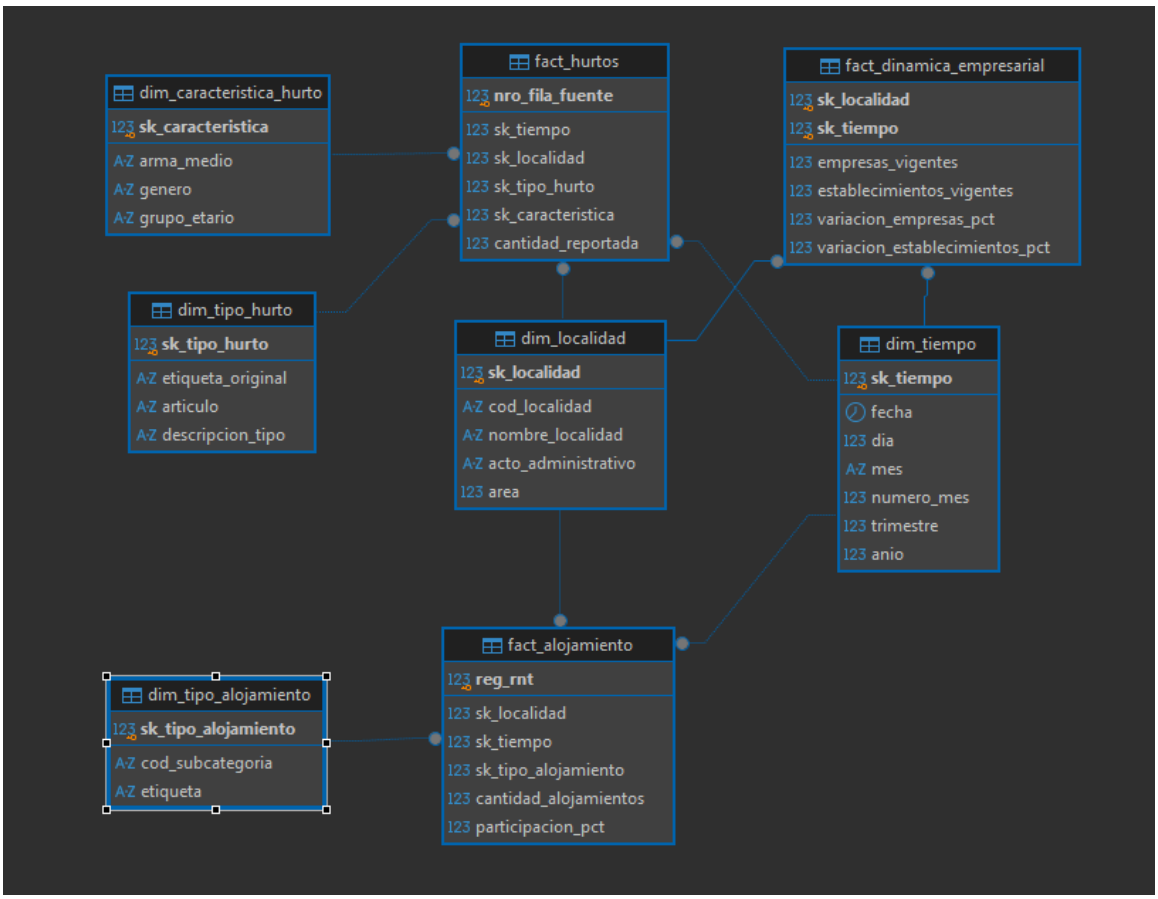


Diagrama ER generado con DBeaver a partir de la base ya creada (esquema `dw`). El archivo PNG se guarda en `docs/diagramas`.

1.4 Dimensión de tiempo

- **Rango:** 01/01/2010 a 31/12/2026, sin huecos: 6.209 días (17 años, 4 de ellos bisiestos).
- **Cómo se pobló:** con la transformación `t_dim_tiempo.ktr`, que genera el calendario diario con `generate_series` de PostgreSQL y lo escribe con *Table output*.
- **Atributos:** `sk_tiempo` (entero AAAAMMDD), `fecha`, `dia`, `mes` (nombre), `numero_mes`, `trimestre` y `anio`. Una restricción comprueba que `sk_tiempo` coincida con la fecha.
- **Cobertura de los hechos:** todos los periodos de las fuentes caen dentro del rango: hurtos del 01/01/2010 al 31/07/2026, cortes de empresas del 01/09/2023, 01/03/2024 y 01/07/2025, y el corte de alojamientos del 22/10/2026.

2. Procesos ETL

El trabajo `j_carga_dw.kjb` ejecuta 8 transformaciones de PDI en orden (primero las dimensiones, al final los hechos) y carga el DW completo en una sola ejecución. Se ejecutó con Pentaho Data Integration 9.4.0.0-343 (Spoon) sin errores.

2.1 Trabajo de carga

Orden de ejecución del trabajo `etl/trabajos/j_carga_dw.kjb`:

1. **Limpiar DW:** borra hechos y dimensiones y conserva los miembros `-1`, de modo que el trabajo se puede repetir.
2. `t_dim_tiempo`
3. `t_dim_localidad`
4. `t_dim_tipo_alojamiento`
5. `t_dim_tipo_hurto`
6. `t_dim_caracteristica_hurto`
7. `t_fact_dinamica_empresarial`
8. `t_fact_alojamiento`
9. `t_fact_hurtos`
10. **Calcular variación % y participación %:** sentencias SQL que llenan `variacion_empresas_pct`, `variacion_establecimientos_pct` (respecto al corte anterior de la misma localidad) y `participacion_pct`.

Las dimensiones van antes que los hechos porque estos resuelven sus llaves con *Database lookup*; si no hay coincidencia, la fila va al miembro `-1`. Las variables de conexión y las rutas (`DB_HOST`, `DB_PORT`, `DB_NAME`, `DB_USER`, `DB_PASSWORD`, `RAIZ_REPO`, `ARCHIVO_HURTOS`, `FECHA_CORTE_TURISMO`) se leen de `kettle.properties`, que no se sube al repositorio.

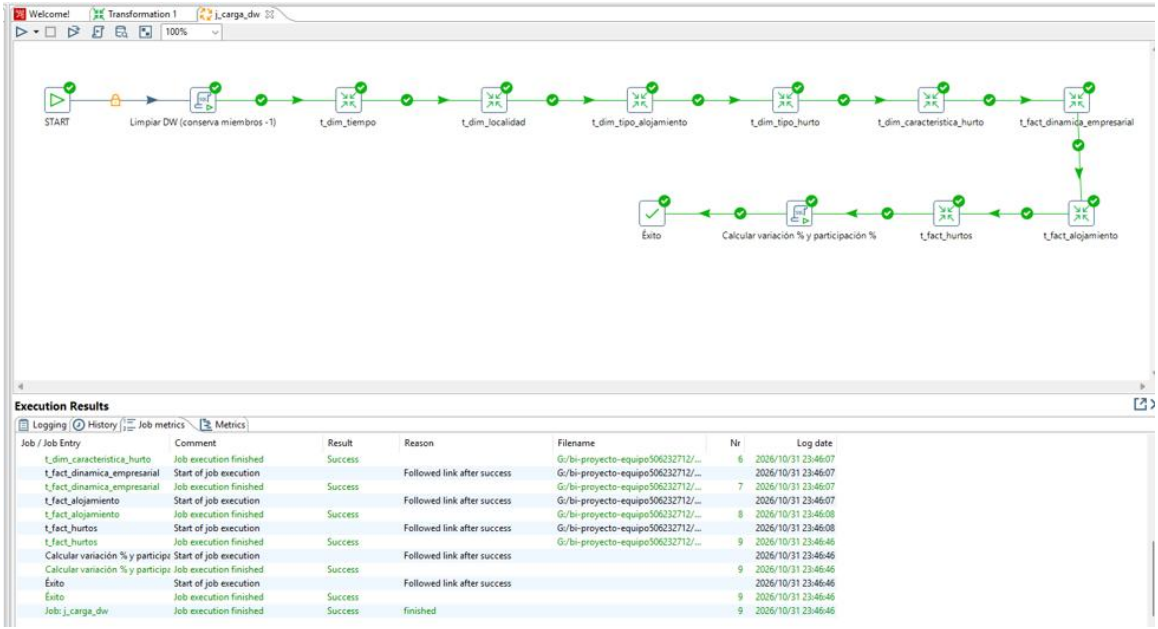


Figura: trabajo `j_carga_dw.kjb` ejecutado en Spoon. Las 10 entradas terminaron en verde (Success) y el trabajo finalizó el 31/10/2026 a las 23:46.

2.2 Transformaciones

Los conteos de la tabla son los del DW cargado, verificados en la conciliación (sección 3). Para F3, *Leídos* cuenta las filas agregadas por localidad y corte: la consulta suma antes las 119.893 filas de la capa `Empresas` y las 12.923 de `Establecimientos`.

Archivo .ktr	Fuente(s) y formato	Destino	Pasos principales	Leídos	Escritos	Rechazos
t_dim_tiempo.ktr	Calendario generado con `generate_series` (PostgreSQL)	dim_tiempo	Table input → Table output	6.209	6.209	0
t_dim_localidad.ktr	F4 `geografia.json` (JSON) y tabla de equivalencia (CSV)	dim_localidad	JSON input → Select values → Stream lookup → Filter rows → Unique rows → Table output	20	20	0
t_dim_tipo_alojamiento.ktr	F1 `turismo.geojson` (JSON)	dim_tipo_alojamiento	JSON input → Modified JavaScript → Unique rows →	839	7	0

Archivo .ktr	Fuente(s) y formato	Destino	Pasos principales	Leídos	Escritos	Rechazos
			Table output			
t_dim_tipo_hurto.ktr	F2 CSV de hurtos con LOCALIDAD	dim_tipo_hurto	CSV input → Select values → Modified JavaScript → Unique rows → Table output	176.776	2	0
t_dim_caracteristica_hurto.ktr	F2 CSV de hurtos con LOCALIDAD	dim_caracteristica_hurto	CSV input → Select values → Modified JavaScript → Unique rows → Table output	176.776	68	0
t_fact_dinamica_empresarial.ktr	F3 tres GeoPackage (`dinamicaempresarial2023/2024/2025.gpkg`, SQLite vía JDBC) y tabla de equivalencia	fact_dinamica_empresarial	Table input (×3) → Select values → Modified JavaScript → Stream lookup → Database lookup → Table output	60	60	0
t_fact_alojamiento.ktr	F1 `turismo.geojson` (JSON) y tabla de equivalencia	fact_alojamiento	JSON input → Modified JavaScript → Stream lookup → Database lookup (×2) → Table output	839	839	0
t_fact_hurtos.ktr	F2 CSV de hurtos con LOCALIDAD y tabla de equivalencia	fact_hurtos	CSV input → Select values → Modified JavaScript → Stream lookup → Database lookup (×3) → Table output	176.776	176.776	0

F2 se lee del CSV que ya contiene solo las 176.776 filas de Bogotá (la columna `LOCALIDAD` se agrega con `etl/scripts/asignar_localidad.py`). Si se usa el CSV completo (653.384 filas), la regla P04 descarta 476.608.

2.3 Reglas de limpieza aplicadas

Una fila por cada problema de la tabla 2.2 de la Entrega 1. Los nombres de los pasos empiezan por el código del problema (`P01` a `P15`). Los registros afectados se calcularon directamente de los archivos fuente y se verifican en el log y en *Step Metrics* de la ejecución (detalle en `etl/reglas_calidad.md`).

Problema (Entrega 1)	Fuente y campo	Regla aplicada	Paso de PDI (nombre)	Registros afectados
P01. Código de localidad sin cero a la izquierda	F1.LOCALIDAD	Completar a 2 dígitos («3» → «03») y homologar con la tabla de equivalencia	P01-F1 Completar LOCALIDAD a 2 digitos (3 -> 03)	438 de 839
P02. Dos sistemas de coordenadas	F1.geometría, LATITUD, LONGITUD	Excluir geometría y coordenadas: del alojamiento solo se usa la localidad, así que no hace falta reproyectar	P02-F1 Excluir geometria (EPSG:3857) y LATITUD/LONGITUD; solo se usa LOCALIDAD	839
P03. SUBCATRNT con códigos numéricos; el diccionario usa letras	F1.SUBCATRNT	Conservar el código numérico y dejar `etiqueta` en NULL, sin asignar nombres sin certeza	P03-F1 Conservar codigo numerico SUBCATRNT (sin etiqueta A-Z)	839 filas, 7 códigos (6 a 12)
P04. Hurtos: solo se identifica a Bogotá, no la localidad	F2.DEPARTAMENTO, MUNICIPIO, CODIGO DANE	Filtrar `DEPARTAMENTO = BOGOTA` y verificar municipio y código DANE	P04-F2 Filtrar solo Bogota D.C. (DEPARTAMENTO = BOGOTA)	476.608 descartadas del CSV completo; 176.776 pasan; 0 incoherentes
P05. Fecha como texto dd/mm/aaaa	F2.FECHA HECHO	Convertir a `sk_tiempo` (AAAAMMDD)	P05-F2 Convertir FECHA HECHO (dd/mm/aaaa) a sk_tiempo	0 inválidas (rango 01/01/2010 a 31/07/2026)
P06. Cantidad como texto	F2.CANTIDAD	Validar entero mayor que 0; se conserva `cantidad_reportada`	P06-F2 Validar CANTIDAD entera mayor que 0	0 inválidas; suma 176.776

Problema (Entrega 1)	Fuente y campo	Regla aplicada	Paso de PDI (nombre)	Registros afectados
P07. Género y grupo etario vacíos	F2.GENERO, GRUPO ETARIO	Etiqueta `SIN DATO`; sin imputar categorías	P07-F2 Vacios de genero, grupo etario y arma -> SIN DATO	160.540 de género; 14.811 de grupo etario
P08. Solo dos tipos de hurto; ARMAS MEDIOS incluye NO REPORTADO	F2.TIPO DE HURTO, ARMAS MEDIOS	Separar artículo y descripción; conservar NO REPORTADO como categoría	P08-F2 Tipificar tipo de hurto (articulo + descripcion)	2 tipos en `dim_tipo_hurto`
P09. Localidad: columna añadida, con tildes y «La Candelaria»	F2.LOCALIDAD	Normalizar el nombre y homologar con la tabla de equivalencia (`equivalencia_localidad.csv`)	P09-F2 Homologar LOCALIDAD con tabla de equivalencia	0 sin equivalencia; 8.838 u 8.839 por localidad
P10. Filas que repiten los nueve campos originales	F2 (todos los campos)	No se marcan ni se eliminan: se cuentan en una rama paralela y las 176.776 filas se cargan	P10-F2 Detectar repeticiones de los 9 campos originales (solo conteo)	144.063 repeticiones posibles
P11. Código y nombre de localidad inconsistentes; código 21 «Sin Localidad»	F3.LOCCODIGO, LOCNOMBRE	Agrupar por nombre (el código de 2025 es un índice erróneo) y homologar; 21 y «Sin Localidad» van al miembro -1	P11-F3 Unificar identificador de localidad (codigo o nombre)	20 (2025); 2 (2023 y 2024)
P12. Establecimientos de 2023 sin dato	F3.EstablecimientosVigentes	Conservar NULL; no imputar	P12-F3 Conservar NULL de establecimientos (no imputar)	20
P13. Grafía distinta de nombres y un corte por archivo	F3.LOCNOMBRE, Periodo, Mes	Homologar la grafía con la tabla y tomar el corte del Periodo y Mes	P13-F3 {año} detalle agregado por localidad y corte	20 nombres con grafía distinta (2025); cortes 20230901, 20240301 y

Problema (Entrega 1)	Fuente y campo	Regla aplicada	Paso de PDI (nombre)	Registros afectados
		del archivo	(Periodo/Mes)	20250701
P14. Nombres de F4 en mayúsculas sin tildes	F4.LocNombre	Buscar el nombre en la tabla de equivalencia y validar que resuelva al mismo código	P14-F4 Buscar nombre en tabla de equivalencia	0 rechazados de 20
P15. Sistema de referencia EPSG:4686 y sin diccionario	F4.geometría	Excluir la geometría y conservar solo atributos	P15-F4 Excluir geometria (EPSG:4686) y conservar solo atributos	20

Además hay pasos de control `C-…` que no están en la tabla 2.2 (llaves nulas, duplicados de llave, valores inválidos). Con los datos actuales rechazan 0 filas.

Supuesto de F3: las sumas de `EmpresasVigentes` ignoran los valores nulos de la capa de detalle (4.267, 273 y 1.256 filas nulas en 2023, 2024 y 2025).

2.4 Evidencia de ejecución

El trabajo terminó sin errores y la conciliación posterior dio 85 de 85 comprobaciones en OK (sección 3).

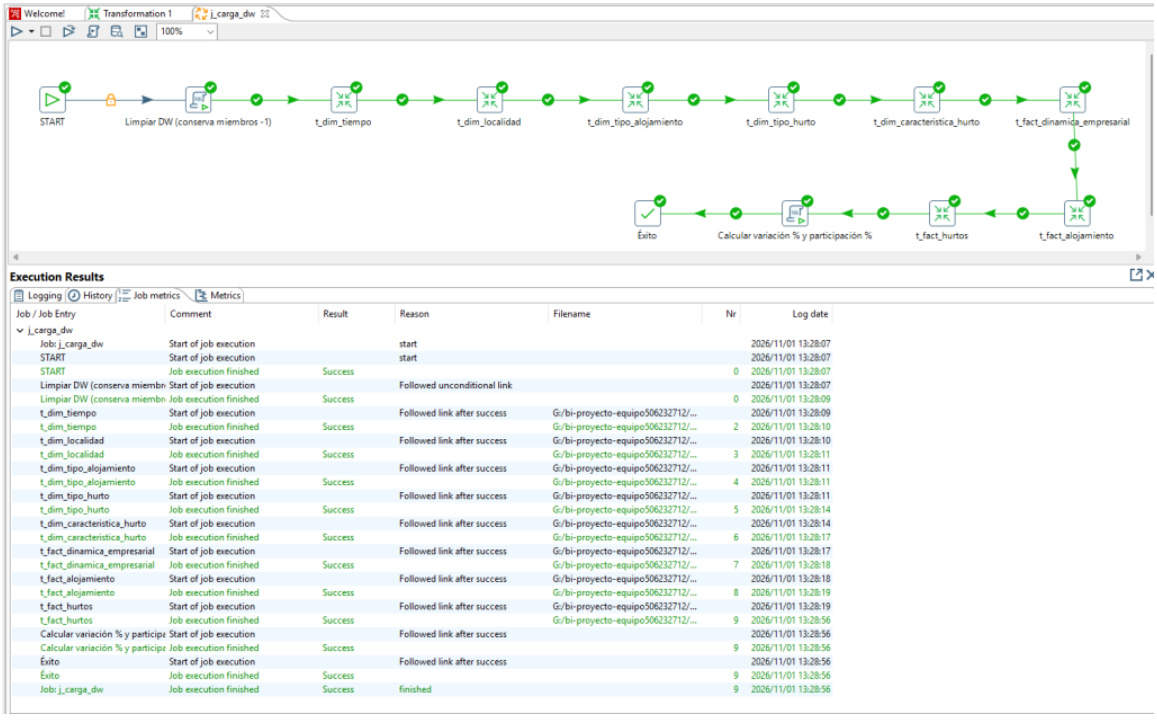


Figura: ejecución completa de `j_carga_dw.kjb` en Spoon, con la pestaña Job metrics. Las ocho transformaciones y el cálculo de variación y participación terminaron en Success.

3. Conciliación

Las 85 comprobaciones de filas y cantidades entre las fuentes y el DW coinciden: 85 en OK y 0 diferencias. Los valores esperados se calcularon con Python directamente de los archivos originales (`dw/conciliacion/generar_valores_fuente.py`), de forma independiente del ETL, y se compararon con las tablas del DW mediante `dw/conciliacion/02_conciliar.sql`.

3.1 Conteo por fuente

Fuente	Leídos	Cargados	Descartados	Motivo de los descartes
F1. Registro Nacional de Turismo (`turismo.geojson`)	839	839	0	No hubo descartes: las 839 filas tienen localidad y subcategoría válidas
F2. Hurtos por modalidades (CSV de la Policía)	653.384	176.776	476.608	Filas de otros departamentos: se filtra `DEPARTAMENTO = BOGOTA` (176.776 filas, 27,1 % del archivo). El trabajo de PDI lee el CSV que ya trae solo Bogotá, y todas sus filas se cargan
F3. Dinámica empresarial (3 GeoPackage)	132.816 filas de detalle (119.893 de `Empresas` y 12.923 de `Establecimientos`)	60	0	No hay descartes. Cambia el grano: el detalle se suma por localidad y corte, lo que da 20 localidades × 3 cortes = 60 filas

F3 no cumple «legídos = cargados + descartados» porque es una agregación; en su lugar se comprueba que cada suma por corte coincida con la fuente (ver 3.2). Para F1 y F2 se cumple: 839 = 839 + 0 y 176.776 = 176.776 + 0 tras el filtro de Bogotá.

3.2 Totales de una métrica

Métrica	Total en la fuente	Total en el DW	Diferencia y explicación
Suma de `CANTIDAD` de hurtos (F2)	176.776	176.776	0. La cantidad es 1 en todas las filas
Filas de hurtos por año, 2010 a 2026	176.776	176.776	0 en cada año (por ejemplo,

Métrica	Total en la fuente	Total en el DW	Diferencia y explicación
(17 años)			2025: 14.281; 2026: 9.173)
Filas de hurtos por localidad (20)	8.839 × 16 + 8.838 × 4	igual	0. Es el reparto equitativo de la `LOCALIDAD` asignada por el equipo
Empresas vigentes, corte 2023-09 (F3)	400.077	400.077	0
Empresas vigentes, corte 2024-03 (F3)	450.376	450.376	0
Empresas vigentes, corte 2025-07 (F3)	378.759	378.759	0
Establecimientos vigentes, corte 2024-03 (F3)	257.751	257.751	0
Establecimientos vigentes, corte 2025-07 (F3)	221.444	221.444	0
Establecimientos vigentes, corte 2023-09 (F3)	sin dato	sin dato (20 filas NULL)	La fuente no trae el dato; no se imputa
Alojamientos por localidad y por subcategoría (F1)	839	839	0 en cada una de las 17 localidades con alojamientos y en las 7 subcategorías
Filas de las dimensiones	tiempo 6.209; localidad 20; tipo de alojamiento 7; tipo de hurto 2; característica 68	igual	0 (sin contar los miembros -1)

Controles de integridad. Los hechos de hurtos y de alojamientos no tienen ninguna llave en `-1`. Lo que sí queda en `-1` se explica por las fuentes:

- 3 filas de `fact_dinamica_empresarial` (una por corte) corresponden al código 21 «Sin Localidad» de F3.
- 20 filas de esa misma tabla tienen establecimientos NULL: el corte de 2023 no los trae.
- 3 localidades no tienen alojamientos en F1 (San Cristóbal, Ciudad Bolívar y Sumapaz), y 1 no tiene dinámica empresarial. Es una característica de la fuente, no un error de carga.

Las consultas completas están en el Anexo A y en `dw/conciliacion/`.

4. Tablero

El tablero de Power BI Desktop tiene 5 páginas y usa solo las tablas `dim_*` y `fact_*` del esquema `dw`, en modo importación, conectado con el usuario de solo lectura `powerbi_lector` (`127.0.0.1:5433`, base `observatorio_bi`). Las relaciones van de cada hecho hacia sus dimensiones, de muchos a uno y con filtro en una sola dirección. Las medidas DAX están en `dashboard/medidas.dax`.

4.1 Indicadores

Cada indicador se muestra frente a una referencia (periodo anterior o promedio histórico). Las cifras de la tabla son las del tablero sin filtros y coinciden con las consultas de `dashboard/consultas_tablero.sql`.

Indicador	Fórmula (DAX)	Qué mide	Referencia	Pregunta
Empresas vigentes (379 mil)	`CALCULATE ( SUM ( fact_dinamica_empresarial[empresas_vigentes] ), fact_dinamica_empresarial[sk_tiempo] = MAX ( fact_dinamica_empresarial[sk_tiempo] ) )`	Empresas vigentes en el último corte (julio de 2025): 378.759	Corte anterior (marzo de 2024): 450.376; variación −15,9 %	P0, P1
Establecimientos vigentes (221 mil)	Igual que el anterior, con `establecimientos_vigentes`	Establecimientos vigentes en el último corte: 221.444	Corte anterior: 257.751; variación −14,1 % (2023 no tiene dato en la fuente)	P0, P1
Promedio mensual de hurtos	`DIVIDE ( [Hurtos registros], COUNTROWS ( FILTER ( VALUES ( dim_tiempo[MesKey] ), [Hurtos registros] > 0 ) ) )`	Registros de hurto por mes con datos: 888,3	Promedio histórico (888,3); al filtrar un año se compara con él (2025: +34,0 %)	P0, P3
Alojamientos inscritos en el RNT	`COUNTROWS ( fact_alojamiento )`	Establecimientos de alojamiento turístico: 839	Promedio por localidad con alojamientos: 49,4	P0, P2

Las variaciones son `DIVIDE ( [Empresas vigentes] - [Empresas corte anterior], [Empresas corte anterior] )` y equivalentes. El corte anterior se calcula con `REMOVEFILTERS ( dim_tiempo )` para que no dependa del segmentador de año.

4.2 Respuesta a las preguntas de negocio

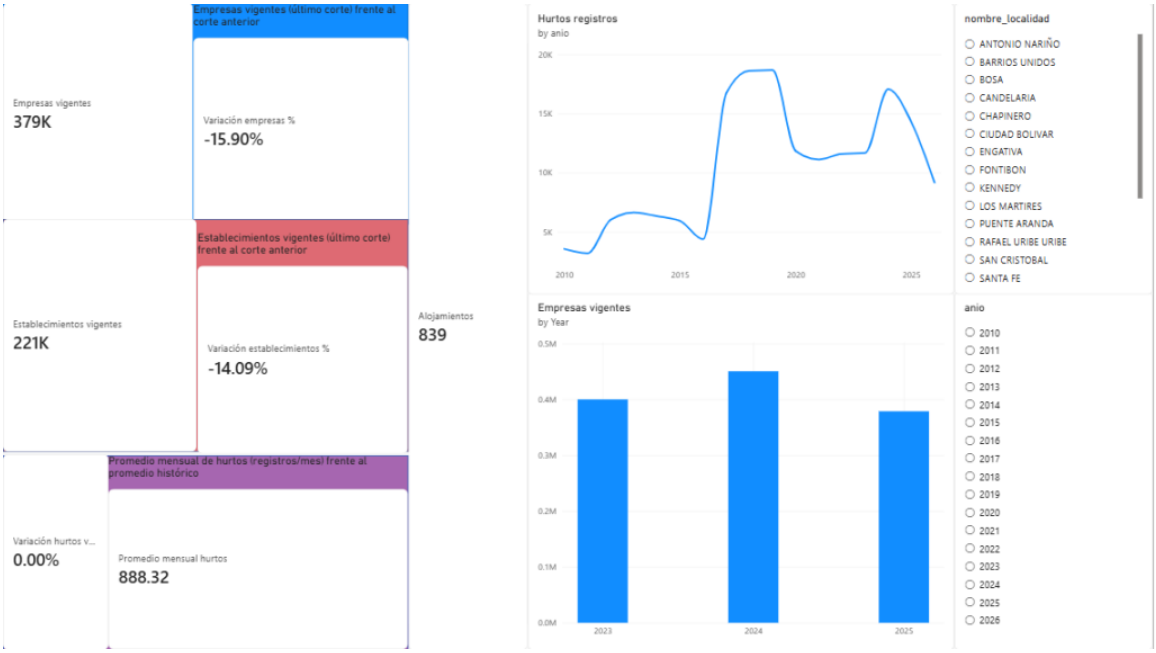
Pregunta	Página y visual	Tipo de gráfico y por qué	Respuesta encontrada (con cifra)
P0. Distribución y evolución de la actividad empresarial, los alojamientos y los hurtos en Bogotá	Página 1 «Panorama de Bogotá»: tres indicadores, tarjeta de alojamientos, línea de hurtos y columnas de empresas por corte	Indicadores con referencia (una cifra y su cambio), línea para la serie anual de hurtos y columnas para tres cortes puntuales	Las empresas vigentes bajaron de 450.376 (marzo de 2024) a 378.759 (julio de 2025), −15,9 %; los establecimientos, de 257.751 a 221.444 (−14,1 %). Hay 839 alojamientos en el RNT (corte de octubre de 2026) y 176.776 registros de hurto entre 2010 y julio de 2026, con un promedio de 888,3 por mes
P1. Localidades con más empresas y establecimientos y su evolución entre cortes	Página 2: barras de empresas por localidad, columnas agrupadas por corte y tabla con variación	Barras ordenadas (ranking de una medida entre localidades), columnas por corte (tres puntos, no una serie continua) y tabla para comparar dos medidas	Suba lidera con 46.228 empresas y 22.882 establecimientos, seguida de Usaquén (38.307), Chapinero (36.815), Kennedy (36.587) y Engativá (32.896). Todas las localidades bajaron entre cortes (de −6,2 % a −22,2 %); la mayor caída es San Cristóbal (−22,2 %)
P2. Distribución de los alojamientos por localidad y subcategorías representadas	Página 3: barras de alojamientos por localidad con línea de promedio y barras por código de subcategoría	Barras horizontales: categorías nominales sin orden natural; la línea de promedio da la referencia	Teusaquillo concentra 209 alojamientos y Chapinero 160, frente a un promedio de 49,4 por localidad. La subcategoría 9 agrupa 668 de los 839 (79,6 %). Tres localidades no tienen alojamientos en la fuente (San Cristóbal, Ciudad Bolívar y Sumapaz)
P3. Evolución de registros y cantidades de hurto por fecha, tipo y otras características	Página 4: línea anual, columnas por tipo de hurto, barras por arma o medio, columnas por grupo etario y género, y barras	Línea para la evolución temporal; barras y columnas para comparar categorías	Los registros pasan de 3.554 (2010) a un máximo de 18.690 (2019), bajan a 11.841 en 2020 y suben a 17.071 en 2024; 2025 cierra en 14.281 y 2026 (enero a julio) lleva 9.173. Predomina el hurto a entidades comerciales; la mayor parte de los hechos son sin empleo de armas. El género es «SIN DATO» en 160.540 filas (90,8 %)

Pregunta	Página y visual	Tipo de gráfico y por qué	Respuesta encontrada (con cifra)
	por localidad		
P4. Comparación descriptiva de empresas, alojamiento y hurtos sin inferir causalidad	Página 5: líneas de índice base 2023 = 100 y tabla comparativa por localidad	Índice con base común para poner en la misma escala magnitudes distintas (cortes puntuales de empresas y años completos de hurtos)	Entre 2023 y 2025 el índice de empresas sube a 112,6 en 2024 y cae a 94,7 en 2025; el de hurtos sube a 146,4 en 2024 y queda en 122,4 en 2025. Son series descriptivas: no se concluye que una explique la otra

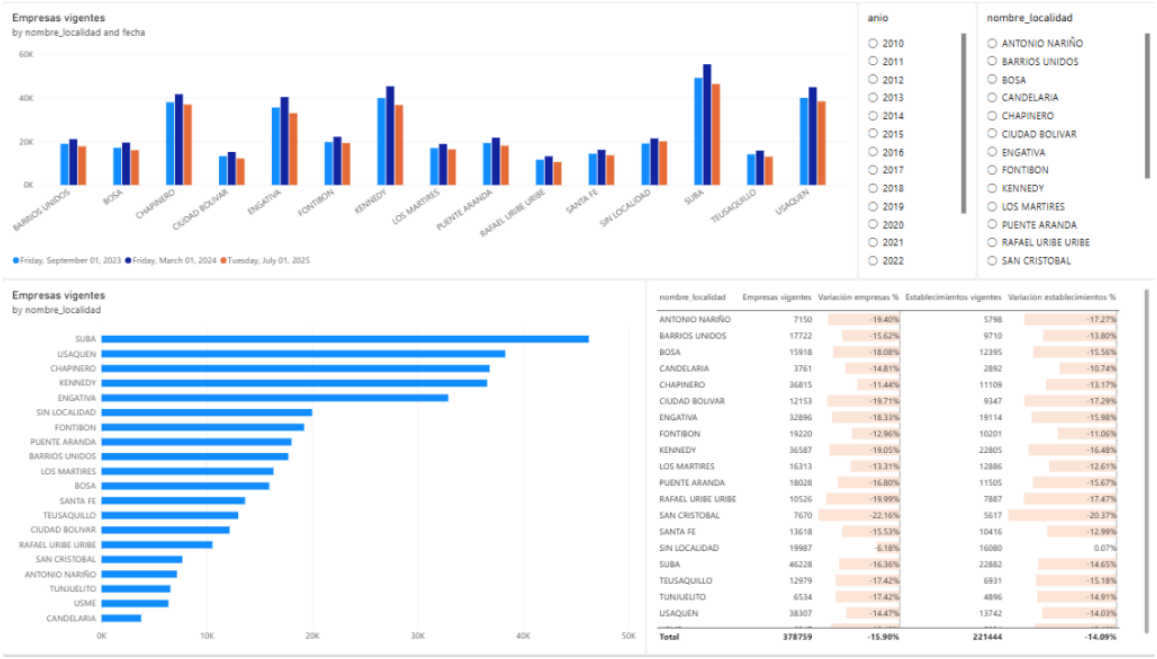
4.3 Capturas del tablero

Una captura por página, con su título. El archivo `.pbix` y las mismas capturas van en `/dashboard` del repositorio.

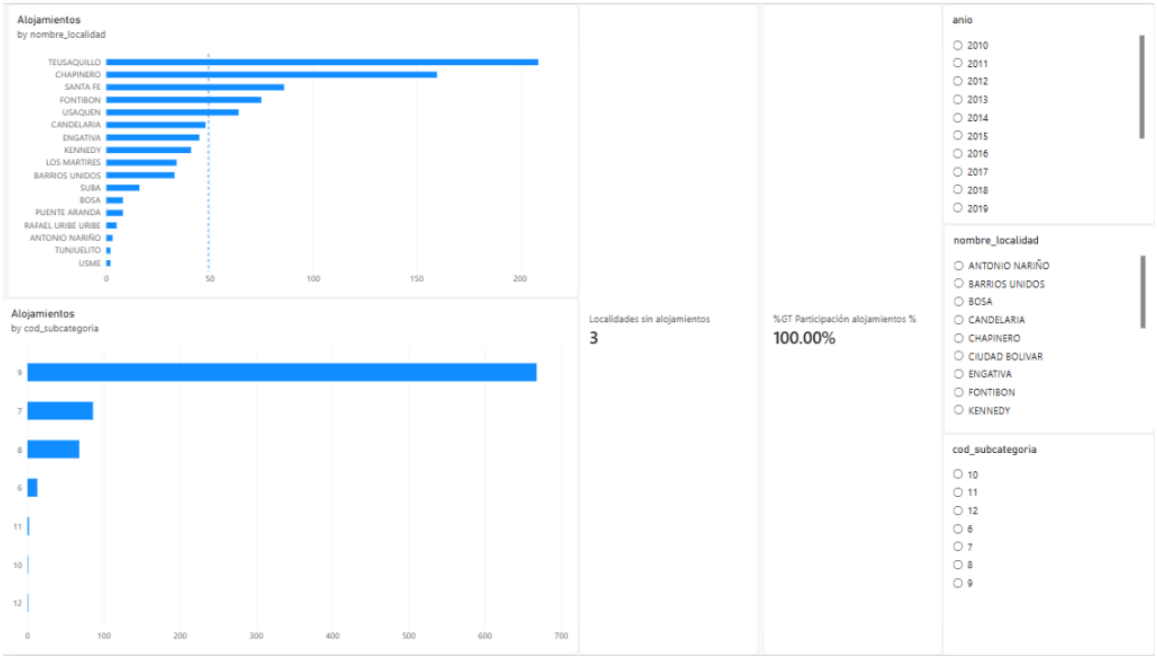
Página 1 · Panorama de Bogotá (P0)



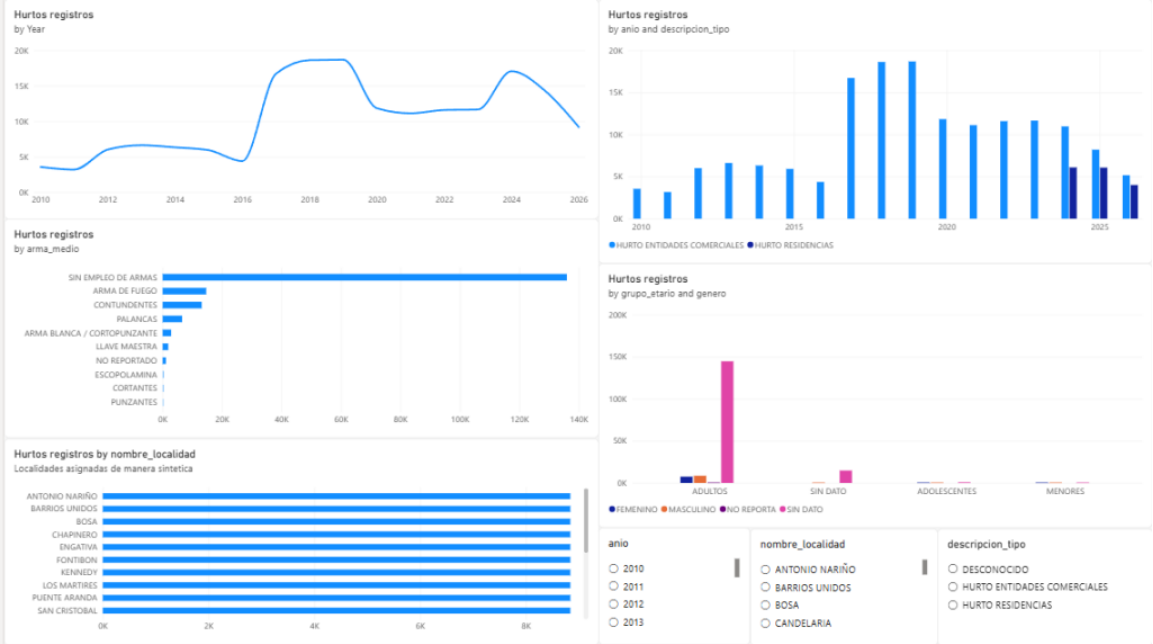
Página 2 · Actividad empresarial por localidad (P1)



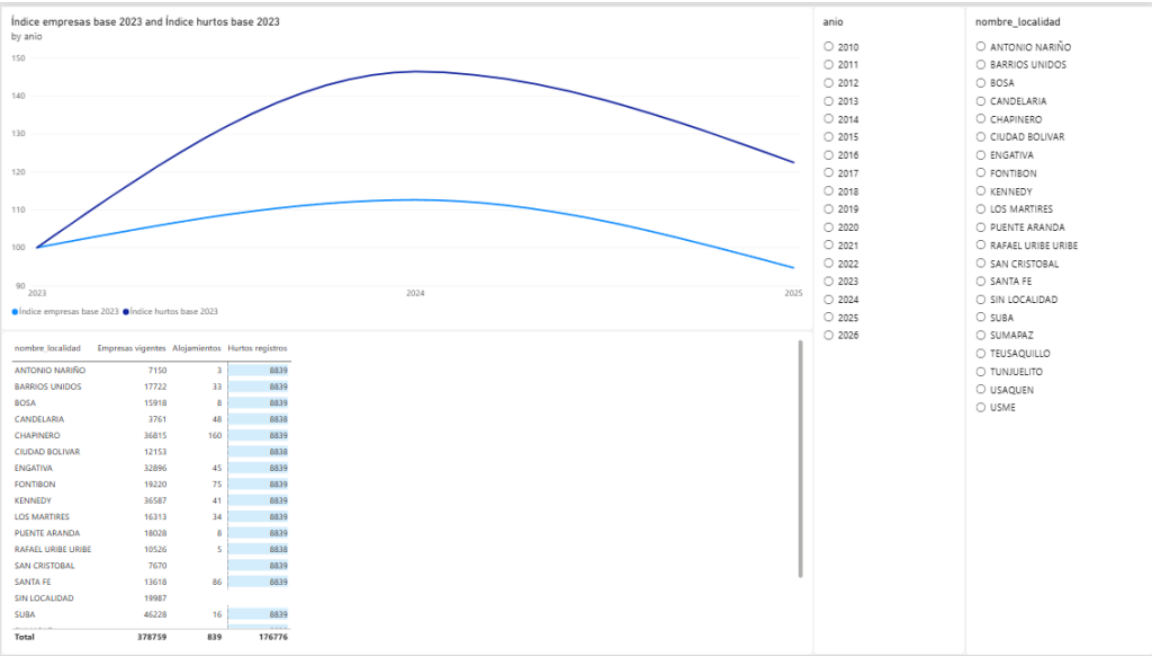
Página 3 · Alojamiento turístico por localidad (P2)



Página 4 · Hurtos por modalidades (P3)



Página 5 · Comparación descriptiva (P4)



4.4 Filtros

Segmentador	Campo	Páginas en las que actúa	Observación
Año	`dim_tiempo[anio]`	1, 2, 3, 4	Tiempo. En la página 3 solo 2026 devuelve datos (la fuente de alojamientos tiene un

Segmentador	Campo	Páginas en las que actúa	Observación
		y 5	solo corte); empresas solo tiene datos en 2023, 2024 y 2025
Localidad	`dim_localidad[nombre_localidad]`	1, 2, 3, 4 y 5	Incluye «SIN LOCALIDAD» (código 21 de F3)
Subcategoría	`dim_tipo_alojamiento[cod_subcategoria]`	3	Se muestra el código original de SUBCATRNT; el diccionario no permite verificar los nombres
Tipo de hurto	`dim_tipo_hurto[descripcion_tipo]`	4	Incluye el miembro de control «DESCONOCIDO», sin registros

Advertencias que se declaran en el tablero y en este informe:

- La `LOCALIDAD` de los hurtos fue asignada por el equipo de forma simulada y equitativa (8.838 u 8.839 filas por localidad), con autorización del docente. Cualquier cifra de hurtos por localidad refleja ese reparto, no la realidad.
- Los cortes de F3 (septiembre de 2023, marzo de 2024 y julio de 2025) no son continuos ni equidistantes.
- 2026 es parcial en hurtos (enero a julio).
- Los hurtos incluyen repeticiones posibles de los nueve campos originales (144.063 filas): no se marcaron ni se eliminaron, de modo que `COUNT(*)` las incluye.
- No se cargan coordenadas de los alojamientos: del alojamiento solo se usa la localidad.

Anexos

Anexo A. Consultas de conciliación

Las consultas de la sección 3 son las de `/dw/conciliacion`. Orden de ejecución, conectado a `observatorio_bi` después de correr el trabajo de PDI:

1. `python dw/conciliacion/generar_valores_fuente.py` calcula los valores esperados de los archivos originales y escribe `01_valores_fuente.sql` (107 valores).
2. `00_tabla_conteos_pdi.sql` crea `stg.conciliacion_pdi`.
3. `01_valores_fuente.sql` carga `stg.conciliacion_fuente`.
4. `02_conciliar.sql` compara lo esperado con lo cargado. Se muestran sus consultas principales (valores del DW, sección 1 y resumen).

```
-- Valores que quedaron en el DW, con los mismos nombres de concepto que
stg.conciliacion_fuente
CREATE TEMP TABLE dw_vals AS
SELECT 'F1'::text AS fuente, 'cmp_filas_total'::text AS concepto, ''::text AS clave,
COUNT(*)::numeric AS valor FROM dw.fact_alojamiento
```

```
UNION ALL SELECT 'F1', 'cmp_filas_localidad', l.cod_localidad, COUNT(*) FROM
dw.fact_alojamiento f JOIN dw.dim_localidad l USING (sk_localidad)
          WHERE l.sk_localidad <> -1 GROUP BY l.cod_localidad
UNION ALL SELECT 'F1', 'cmp_filas_subcategoria', t.cod_subcategoria, COUNT(*) FROM
dw.fact_alojamiento f JOIN dw.dim_tipo_alojamiento t USING (sk_tipo_alojamiento)
          WHERE t.sk_tipo_alojamiento <> -1 GROUP BY t.cod_subcategoria
UNION ALL SELECT 'F2', 'cmp_filas_total', '', COUNT(*) FROM dw.fact_hurtos
UNION ALL SELECT 'F2', 'cmp_suma_cantidad', '', SUM(cantidad_reportada) FROM
dw.fact_hurtos
UNION ALL SELECT 'F2', 'cmp_filas_anio', t.anio::text, COUNT(*) FROM dw.fact_hurtos f
JOIN dw.dim_tiempo t USING (sk_tiempo) GROUP BY t.anio
UNION ALL SELECT 'F2', 'cmp_filas_localidad', l.cod_localidad, COUNT(*) FROM
dw.fact_hurtos f JOIN dw.dim_localidad l USING (sk_localidad)
          WHERE l.sk_localidad <> -1 GROUP BY l.cod_localidad
UNION ALL SELECT 'F3', 'cmp_filas_total', '', COUNT(*) FROM
dw.fact_dinamica_empresarial
UNION ALL SELECT 'F3', 'cmp_empresas_corte', sk_tiempo::text, SUM(empresas_vigentes)
FROM dw.fact_dinamica_empresarial GROUP BY sk_tiempo
UNION ALL SELECT 'F3', 'cmp_establecimientos_corte', sk_tiempo::text,
SUM(establecimientos_vigentes) FROM dw.fact_dinamica_empresarial GROUP BY sk_tiempo
UNION ALL SELECT 'DIM', 'cmp_dim_tiempo', '', COUNT(*) FROM dw.dim_tiempo;
-- (el archivo completo incluye también género y grupo etario sin dato, filas por
corte, nulos y las demás dimensiones)

-- 1) Leídos = cargados + descartados (F1 y F2)
WITH f AS (SELECT fuente, concepto, clave, valor FROM stg.conciliacion_fuente),
flujo AS (
  SELECT x.fuente,
         (SELECT valor FROM f WHERE fuente = x.fuente AND concepto = 'info_leidas')
AS leidas,
         COALESCE((SELECT SUM(valor) FROM f WHERE fuente = x.fuente AND concepto LIKE
'info\_descartadas\_%'), 0) AS descartadas,
         (SELECT valor FROM dw_vals WHERE fuente = x.fuente AND concepto =
'cmp_filas_total') AS cargadas_dw
    FROM (VALUES ('F1'), ('F2')) AS x(fuente)
)
SELECT fuente, leidas, descartadas, leidas - descartadas AS esperadas_cargadas,
cargadas_dw,
       cargadas_dw - (leidas - descartadas) AS diferencia,
       CASE WHEN cargadas_dw = leidas - descartadas THEN 'OK' ELSE 'DIFERENCIA' END
AS estado
  FROM flujo ORDER BY fuente;

-- 2) Esperado (fuente) frente a cargado (DW)
CREATE TEMP TABLE comparacion AS
SELECT COALESCE(s.fuente, d.fuente) AS fuente, COALESCE(s.concepto, d.concepto) AS
concepto,
       COALESCE(s.clave, d.clave, '') AS clave, s.valor AS esperado_fuente, d.valor
AS cargado_dw,
       CASE WHEN s.valor IS NOT DISTINCT FROM d.valor THEN 'OK' ELSE 'DIFERENCIA' END
AS estado
  FROM (SELECT * FROM stg.conciliacion_fuente WHERE concepto LIKE 'cmp\_%') s
  FULL JOIN (SELECT fuente, concepto, COALESCE(clave, '') AS clave, valor FROM
dw_vals) d
    ON d.fuente = s.fuente AND d.concepto = s.concepto AND d.clave = s.clave;
```

```
-- 3) Resumen
SELECT COUNT(*) AS comprobaciones, COUNT(*) FILTER (WHERE estado = 'OK') AS ok,
       COUNT(*) FILTER (WHERE estado <> 'OK') AS diferencias,
       CASE WHEN COUNT(*) FILTER (WHERE estado <> 'OK') = 0 THEN 'CONCILIACION OK'
ELSE 'REVISAR DIFERENCIAS' END AS resultado
  FROM comparacion;
```

Resultado de la ejecución (salida completa en `/evidencia/salida_02_conciliar.txt`):

Fuente	Leídas	Descartadas	Esperadas cargadas	Cargadas en el DW	Diferencia	Estado
F1	839	0	839	839	0	OK
F2	176.776	0	176.776	176.776	0	OK

Comprobaciones	OK	Diferencias	Resultado
85	85	0	CONCILIACION OK

Controles de integridad (sección 5 de `02_conciliar.sql`):

Control	Filas
fact_hurtos con localidad, tipo de hurto o característica en -1	0
fact_alojamiento con localidad o tipo en -1	0
fact_dinamica_empresarial con localidad -1 (código 21 «Sin Localidad»)	3
fact_dinamica_empresarial con establecimientos NULL (2023 sin dato)	20
Localidades sin ningún hurto	0
Localidades sin ningún alojamiento	3
Localidades sin dinámica empresarial	1

Anexo B. Capturas adicionales

Salida de `03_verificar_modelo.sql` (tabla 1.2). Las 8 tablas tienen llave primaria, los hechos tienen 3, 2 y 4 llaves foráneas y los conteos coinciden con los de la sección 1.2. Llaves foráneas verificadas en el catálogo de PostgreSQL:

Tabla de hechos	Columna	Dimensión referenciada	Restricción
fact_dinamica_empresarial	sk_localidad	dim_localidad	fk_fact_dinamica_localidad
fact_dinamica_empres	sk_tiempo	dim_tiempo	fk_fact_dinamica_tiem

Tabla de hechos	Columna	Dimensión referenciada	Restricción
arial			po
fact_alojamiento	sk_localidad	dim_localidad	fk_fact_alojamiento_localidad
fact_alojamiento	sk_tiempo	dim_tiempo	fk_fact_alojamiento_tiempo
fact_alojamiento	sk_tipo_alojamiento	dim_tipo_alojamiento	fk_fact_alojamiento_tipo
fact_hurtos	sk_caracteristica	dim_caracteristica_hurto	fk_fact_hurtos_caracteristica
fact_hurtos	sk_localidad	dim_localidad	fk_fact_hurtos_localidad
fact_hurtos	sk_tiempo	dim_tiempo	fk_fact_hurtos_tiempo
fact_hurtos	sk_tipo_hurto	dim_tipo_hurto	fk_fact_hurtos_tipo

La salida completa (41 columnas con su tipo y si admiten nulos, más los registros por tabla) va en `/evidencia/salida_03_verificar_modelo.txt`.

Vista de relaciones del modelo en Power BI. Cada hecho se une a sus dimensiones de muchos a uno (`*` hacia `1`), con filtro en una sola dirección; `dim_tiempo` y `dim_localidad` se comparten entre los tres hechos. `MesKey` es la columna calculada de `dim_tiempo` usada por las medidas.



Pendiente del equipo (opcional): captura de `t_fact_hurtos.ktr` con Step Metrics y lista de medidas del modelo.

El log completo de la ejecución del trabajo (`log_ejecucion_j_carga_dw.txt`) está en `/evidencia`.